

# **01BAPS**

Bc. Martin Kovanda  
dle přednášek Ing. Václava Kůse, Ph.D.

7. března 2021

# Obsah

<b>1 Úvodní motivační úlohy</b>	<b>1</b>
<b>2 Bayesovský princip</b>	<b>2</b>
<b>3 Další používané principy</b>	<b>7</b>
<b>4 Třídy optimálních strategií, užitková funkce</b>	<b>9</b>
4.1 Statistical decision theory . . . . .	9
<b>5 Rozhodovací principy statistiky</b>	<b>11</b>
5.1 Metoda A) minimalizace L: . . . . .	11
5.2 Metoda B) minimalizace EL . . . . .	11
5.3 Metoda C) Strategie MINIMAXní . . . . .	12
5.4 Metoda D) Bayesovská riziková funkce . . . . .	13
5.5 Úloha predikce . . . . .	14
<b>6 Asymptotické vlastnosti aposteriorní hustoty a Bayesovských bodových odhadů</b>	<b>16</b>
<b>7 Princip neurčitosti</b>	<b>19</b>
7.1 Jeffreysova hustota . . . . .	19
<b>8 Konjugované systémy apriorních hustot, princip maximální entropie</b>	<b>22</b>
8.1 Limitní aposteriorní hustoty ( $\hat{\theta}_B$ ) . . . . .	22
8.2 Konjugované rodiny . . . . .	23
<b>9 Nejméně příznivá apriorní rozdělení</b>	<b>25</b>
9.1 Propojování Bayesovské statistiky s klasickou statistikou (nejméně příznivé rozdělení) . . . . .	25
<b>10 Přípustnost Bayesovského řešení, Steinův efekt, Bergerův jev</b>	<b>29</b>
10.1 Přípustnost (Admissibility) . . . . .	29
10.2 Historie hledání odhadu pro přípustné funkce . . . . .	31
10.3 Steinův efekt (1955) . . . . .	32
10.4 Srovnání přístupů . . . . .	32
<b>11 Grupy transformací, ekvivariantní odhady</b>	<b>35</b>
11.1 Equivariantní rozhodovací funkce ( $MRE_qE$ ) . . . . .	35
<b>12 Bayesovské odhady pro kvadratickou a multilineární L</b>	<b>37</b>
12.1 Další volby L . . . . .	38
<b>13 Výpočetní aspekty Bayesovských metod</b>	<b>40</b>
13.1 Numerická integrace . . . . .	40
<b>14 Bayesovská strategie testování hypotéz</b>	<b>41</b>
14.1 Aspekt Bayesovského testování hypotéz . . . . .	43

# Předmluva a poděkování

Materiál byl sestaven na základě online přednášek a prezentací Ing. Václava Kůse, Ph.D. Zmíněné přednášky proběhly v zimním semestru akademického roku 2020/2021 na Fakultě jaderné a fyzikálně inženýrské ČVUT v Praze. Přednášky nebyly uskutečněny prezenční formou vzhledem k probíhající pandemii Covid-19.

Chtěl bych zde poděkovat svým spolužákům Bc. Filipu Mairingerovi za korektury, opravy a členění skriptu, dále Bc. Janu Trödlerovi za opravu přepisu z přednášek a Bc. Filipu Bárovi, který mi pomohl s mnoha obrázky.

Doufám, že Vám skriptum usnadní studium tohoto předmětu, který je velice zajímavý a určitě není na škodu si o něm zjistit více informací, zvláště pokud se zajímáte o strojové učení a umělou inteligenci. Text poměrně kopíruje přednášky, nicméně neobsahuje některé souvislosti a zajímavosti, které na ní byly řečeny. Určitě tedy doporučuji navštěvovat přednášky, především po přečtení dané látky v těchto skriptech, abyste dané souvislosti lépe strávili.

Toto skriptum je určeno posluchačům 1. ročníku navazujícího magisterského studia navštěvujícím kurs 01BAPS *Bayesovské principy ve statistice*, který je zařazen mezi předměty oboru AMSM. Při sestavování textu se předpokládaly znalosti matematiky na úrovni kurzů 01MAB2-4, 01LAB1-2, 01MIP a 01MAS.

# 1 Úvodní motivační úlohy

Ve statistice provádíme experimenty, abychom získali nějaký užitek, případně abychom mohli předvídat budoucí děje.

PŘÍKLAD 1.1 (Požár lesa ve Španělsku).

- Abychom mohli předvídat budoucí požáry lesa, musíme si nejprve rozmyslet, jestli jsou takové požáry náhodné, tedy zda jde o deterministickou nebo stochastickou úlohu.
- V tom případě ale potřebujeme model, který by úlohu popisoval. V rámci toho modelu musíme zkoumat faktory ovlivňující požáry lesa. Těch je však mnoho, a proto musíme vybrat ty relevantní.
- Dále potom záleží na struktuře dat. Vezmeme  $p$  jako pravděpodobnost, že v lese vznikne požár. Vybraný logistický model pro tuto pravděpodobnost vypadá jako

$$p = \frac{e^{\alpha_1 h + \alpha_2 t + \alpha_3 x}}{1 + e^{\alpha_1 h + \alpha_2 t + \alpha_3 x}},$$

kde  $h$  je vlhkost,  $t$  teplota a  $x$  stupeň péče o les.

- Snažíme se nyní odhadnout parametry  $\hat{\alpha}_1, \hat{\alpha}_2, \hat{\alpha}_3$  na základě dostupných dat.

- Dále musíme ověřit tento model na reálné situaci.

PŘÍKLAD 1.2 (Capture-Recapture). V rybníce je  $N$  ryb. Abychom tento počet zjistili, aniž bychom museli vylovit celý rybník, vylovíme nejprve pouze  $r$  ryb, označíme je a pustíme zpět do vody. Dále počkáme, až budou tyto ryby rovnoměrně rozmístěny a vylovíme  $s$  ryb. Z nich bude  $x$  značit počet označených ryb. Rozdělení odpovídající náhodné veličiny  $X$  je potom  $X \sim f_X(x) = \frac{\binom{r}{x} \binom{N-r}{s-x}}{\binom{N}{s}} \sim \text{Hyp}(N, r, s)$ . Nyní nám jde o to odhadnout, jak vypadá  $\hat{N}$  jako odhad počtu ryb v rybníce. Po krátké úvaze dospějeme k tomu, že  $\hat{N} = \frac{rs}{x}$ .

PŘÍKLAD 1.3 (Analýza dat o přežití). Mějme  $X \geq 0$  jako čas do poruchy. Pokud tento problém řešíme stochasticky, máme rozdělení  $X \sim F_X, f_X$  a můžeme hledat hodnotu  $\mathbb{E}[X] = \theta$ , kterou značíme MTTF (*mean time to failure*). Zavedeme dále **intenzitu poruch** jako  $r_X(x) = \frac{f_X(x)}{1 - F_X(x)}$ . Úkolem je potom nalézt  $\hat{\theta}$ , resp.  $\hat{r}_X(x)$ .

PŘÍKLAD 1.4 (MEX). Představme si počítačovou síť, kde máme za úkol kontrolovat síťový přístupový switch. Obecně o jednotlivých uživateli sítě nevíme nic (nevíme, že zrovna dneska bude někdo stahovat filmy apod.) Označme  $X_i$  jako průtok dat od  $i$ -tého uživatele. Potom chceme mít pod kontrolou pravděpodobnost přetečení switchu, tedy  $\mathbb{P}\left(\sum_{i=1}^n X_i > C_X\right) < e^{-\gamma}$  pro relativně vysoká  $\gamma$  (např.  $\gamma \geq 10$ ). Zabýváme se tedy jevy, které se dějí velice zřídka, ale které by mohli mít i vážný dopad, např. analogicky u povodní.

PŘÍKLAD 1.5 (Ekonometrie). Víme, že změna mzdy souvisí se změnou ceny komodity, tedy  $\Delta M \stackrel{?}{\leftrightarrow} \Delta C$  (např.  $\Delta C = \alpha + \beta(\Delta M)^2 + \gamma \ln \Delta M + \varepsilon$ ). Abychom mohli takový regresní vztah odhadnout, potřebujeme data z minulosti  $(\Delta M_i, \Delta C_i)_{i=1}^n$ . Z toho pak lze odhadnout regresní koeficienty  $\hat{\alpha}, \hat{\beta}, \hat{\gamma}$ . Pro zdárné použití modelu potřebujeme znát rozdělení  $\varepsilon$ , což můžeme aproximovat například pomocí CLT jako  $\varepsilon = \sum_{i=1}^n \varepsilon_i \sim \mathcal{N}$ .

## 2 Bayesovský princip

**Věta 2.1** (Bayesova). Mějme  $(H_k)_{k=1}^{n,+\infty}$  jako úplný rozklad  $\Omega$ ,  $A \in \mathcal{A}$ ,  $\mathbb{P}(A) > 0$ . Potom  $\forall k \in \mathbb{N}$  platí, že

$$\mathbb{P}(H_k|A) = \frac{\mathbb{P}(A|H_k)\mathbb{P}(H_k)}{\sum_{j=1}^{n,+\infty} \mathbb{P}(A|H_j)\mathbb{P}(H_j)}.$$

Důkaz.

$$\mathbb{P}(H_k|A) = \frac{\mathbb{P}(H_k \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|H_k)\mathbb{P}(H_k)}{\sum_{j=1}^{n,+\infty} \mathbb{P}(A|H_j)\mathbb{P}(H_j)}.$$

□

PŘÍKLAD 2.2 (Steve). <https://www.youtube.com/watch?v=HZGCoVF3YvM>

**Věta 2.3** (Bayesova pro hustoty). Mějme  $X, Y$  jako náhodné veličiny s  $f_{X,Y}$ . Pak

$$f_{Y|X}(y|x) = \frac{f_{X|Y}(x|y)f_Y(y)}{f_X(x)} = \frac{f_{X|Y}(x|y)f_Y(y)}{\int_Y f_{X|Y}(x|y)f_Y(y)dy}.$$

### Postup

Mějme třídu hustot  $\mathcal{F} = \{f(x, \theta) : \theta \in \Theta \subset \mathbb{R}^k\}$  (což je náš statistický model), kde  $f_{\mathbf{X}} = \prod_{i=1}^n f_{X_i}$ . Chceme určit  $\hat{\theta}$  na základě známých dat  $\mathbf{x}$  (rozhodujeme o hodnotě  $\theta$ ).

- Známujeme parametr  $\theta \sim \pi(\theta)$ , kde  $\pi(\theta)$  je hustota pravděpodobnosti pro  $\theta$ .
- Pokud  $X_i$  iid  $f(x|\theta)$ , pak  $\mathbf{X} = (X_1, \dots, X_n)$  iid  $f_{\mathbf{X}}(\mathbf{x}|\theta)$ .
- Z toho vyplývá, že  $\varphi(\mathbf{x}, \theta) := f(\mathbf{x}|\theta)\pi(\theta)$  a  $m(\mathbf{x}) := \int \varphi(\mathbf{x}, \theta)d\theta = \int f(\mathbf{x}|\theta)\pi(\theta)d\theta$  jsou marginální rozdělení  $\mathbf{X}$  a z Bayesovy věty získáme rovnost

$$\pi(\theta|\mathbf{x}) \stackrel{B}{=} \frac{\varphi(\mathbf{x}, \theta)}{m(\mathbf{x})} = \frac{f(\mathbf{x}|\theta)\pi(\theta)}{\int_{\Theta} f(\mathbf{x}|\theta)\pi(\theta)d\theta}.$$


### Značení

- $\pi(\theta)$  nazýváme **apriorní hustota** (tohle jsme si mysleli o parametru  $\theta$  dříve) a toto znáhodnění  $\theta$  je tedy způsob, jak sumarizovat dosažitelnou informaci o  $\theta$ .
- $\pi(\theta|\mathbf{x})$  nazýváme **aposteriorní hustota** (tohle si o parametru  $\theta$  myslíme teď, potom co jsme naměřili nová data), viz schéma na obrázku 2.1.

$\pi(\theta)$  může představovat:

- objektivní informace, tj. znalost z předchozích úloh (z minulosti),
- subjektivní informace (znalost experta, naše znalost, ...),
- jejich kombinace, tedy  $\pi(\theta) = \alpha_1\pi_1(\theta) + \alpha_2\pi_2(\theta)$ ,  $\alpha_1 + \alpha_2 = 1$ ,
- neurčitost (neznalost), tzn. rovnoměrné rozdělení pro  $\theta$ .

## 2 Bayesovský princip




Obrázek 2.1: Naznačení přechodu od apriorní hustoty  $\theta$  k aposteriorní hustotě pravděpodobnosti  $\theta|\mathbf{x}$  při daných datech.

POZNÁMKA 2.4. Tímto způsobem by se dalo pojmut i strojové učení. To bere nějaká trénovací a testovací data, kde na trénovacích datech dochází k učení modelu a na testovacích datech (která nebyla použita při trénování) pak vyhodnocuje, jak moc daný model funguje.

Takto Bayesovsky víceméně funguje rozhodování, která v praxi děláme za účelem odhadu  $\theta$ :

$$\pi(\theta) \xrightarrow{\text{data}} \pi(\theta|\mathbf{x}) \rightarrow \hat{\theta}_B = \mathbb{E}[\pi(\theta|\mathbf{x})].$$

Chtěli bychom, aby byl náš odhad  $\hat{\theta}_B$  s rostoucím  $n \rightarrow +\infty$  stále méně ovlivněn  $\pi(\theta)$ .



Obrázek 2.2: Možný tvar aposteriorní hustoty pravděpodobnosti. Demonstrace skutečnosti, že Bayesovský MLE odhad nemusí být vždy nejlepší.

POZNÁMKA 2.5. Při určení odhadu parametru  $\theta$  nemusí být vždy nejvhodnější volbou

$$\hat{\theta}_{\text{BMLE}} = \operatorname{argmax}[\pi(\theta|\mathbf{x})].$$


Můžou nastat případy, kdy je střední hodnota aposteriorní hustoty pravděpodobnosti  $\pi$  vhodnější.

PŘÍKLAD 2.6. Představme si, že máme biliárový stůl délky 1 a dva hráče, kteří hrají mezi sebou. První hráč dostane kouli na pozici  $p \in [0, 1]$ . Druhý hráč to neví a chce poté odhadnout místo, kde se koule prvního hráče nachází, čili chce dostat odhad  $\hat{p}$  na základě  $n$  náhodně rozložených šťouchů, o kterých víme, že se buďto dotkly koule, či nikoliv. Máme tedy  $n$  šťouchů s rovnoměrným rozdělením. Označme  $X$  jako počet neťuků,  $X(\omega) = x$ , což jsou data, která máme k dispozici a ptáme se na odhad  $\hat{p} = ?$

- a) Předpokládejme, že 1. hráč je uniformní. Potom  $p \sim \pi(p) = \begin{cases} 1, & p \in (0, 1), \\ 0, & \text{jinak} \end{cases}$  (podle principu neurčitosti). Potom

$$X \sim f(x|p) = \text{Bi}(n, p).$$

## 2 Bayesovský princip



Obrázek 2.3: Kulečníkový stůl a zjišťování polohy  $p$  červené koule.

Dále pak z Bayesovy věty vyjádříme

$$\pi(p|x) = \frac{f \cdot \pi}{\int_0^1 f \pi dp} = \frac{\binom{n}{x} p^x (1-p)^{n-x} \cdot 1}{\int_0^1 \binom{n}{x} p^x (1-p)^{n-x} \cdot 1 dp} = \text{Beta}(x+1, n-x+1).$$

Z toho vypočítáme Bayesovský odhad parametru  $\theta$  jako


$$\hat{\theta}_B = \hat{p}_B = \mathbb{E}[\pi(p|x)] = \mathbb{E}[\text{Beta}(x+1, n-x+1)] = \frac{x+1}{(x+1) + (n-x+1)} = \frac{x+1}{n+2}.$$

Klasický odhad by byl ve tvaru  $\hat{p}_{\text{ML}} = \frac{x}{n}$ .

b)  $p \sim \pi(p) = \text{Beta}(\alpha, \beta)$  Z toho opět získáme ( $c$  a  $c'$  budou značit normovací konstanty)

$$\begin{aligned} \pi(p|x) &= \frac{f \cdot \pi}{\underbrace{\int f \pi dp}_c} = \frac{1}{c} \binom{n}{x} p^x (1-p)^{n-x} \cdot \frac{1}{\text{Beta}(x+1, n-x+1)} p^{\alpha-1} (1-p)^{\beta-1} = \\ &= \frac{1}{c'} p^{x+\alpha-1} (1-p)^{n-x+\beta-1} = \text{Beta}(x+\alpha, n-x+\beta). \end{aligned}$$

Dále  $\hat{p}_B = \mathbb{E}[\text{Beta}(x+\alpha, n-x+\beta)] = \frac{x+\alpha}{n+\alpha+\beta} \doteq \frac{x}{n} = \hat{p}_{\text{ML}}$  pro velká  $n$ , tedy i velká  $x$ .



Obrázek 2.4: Vykreslení změny normálního rozdělení při rostoucím rozptýlu.

$\pi(\theta) = c \neq 0$  konstantní, takže  $\pi(\theta)$  můžeme volit tak, aby  $\int_{\Theta} \pi(\theta) d\theta = +\infty$ .

**Definice 2.7** (Nevlastní apriorní hustota). Definujeme apriorní nevlastní funkci jako hustotu  $\pi(\theta)$  takovou, že

$$\int_{\Theta} \pi(\theta) d\theta = +\infty.$$

## 2 Bayesovský princip

Uvažujeme však pouze takové nevlastní apriorní hustoty, pro které je

$$\pi(\theta|x) = \frac{f \cdot \pi}{\int f \pi d\theta}$$

stále hustotou pravděpodobnosti, tak jak ji známe. Nevlastní hustota  $\pi(\theta)$  tedy stále nese jistou apriorní informaci o  $\theta$ .


PŘÍKLAD 2.8. a) Mějme  $X \sim f(x|\mu) = \mathcal{N}(\mu, 1)$ , kde  $\mu \in \mathbb{R}$ . Dále nechť  $\pi(\mu) = c \neq 0$  na celém  $\mathbb{R}$ . Potom

$$\pi(\mu|x) = \frac{f(x|\mu) \cdot c}{\int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\mu)^2} c d\mu} = \frac{e^{-\frac{1}{2}(\mu-x)^2}}{\sqrt{2\pi}} \sim \mathcal{N}(x, 1).$$

Dále pak

$$\hat{\mu}_B = \mathbb{E}[\mathcal{N}(x, 1)] = x = \hat{\mu}_{ML}.$$


b) Nechť  $f(x|\mu) = \mathcal{N}(\mu, 1)$  a  $\pi(\mu) = \mathcal{N}(0, 10)$ .



Obrázek 2.5: Vykreslení apriorní hustoty a aposteriorní hustoty pravděpodobnosti.

Pojďme nyní udělat apriorní odhad  $\mu$ , tedy  $\hat{\mu}_{apr.} = \mathbb{E}[\mathcal{N}(0, 10)] = 0$ . Nyní mějme navíc data  $x$  kde  $X \sim f(x|\mu) = \mathcal{N}(\mu, 1)$ , která je zadaná. Potom (s použitím konstanty  $c$  pro zpřehlednění) dostaneme, že

$$\pi(\mu|x) = \frac{1}{c} f(x|\mu) \cdot \pi(\mu) = \frac{1}{c} e^{-\frac{1}{2}(x-\mu)^2} e^{-\frac{1}{20}(\mu-0)^2} = \frac{1}{c} e^{-\frac{11}{20}(\mu - \frac{10}{11}x)^2} \sim \mathcal{N}\left(\frac{10}{11}x, \frac{10}{11}\right)$$



Obrázek 2.6: HPD Region.

Pro odhad  $\mu$  pak platí, že

$$\hat{\mu}_B = \mathbb{E}[\pi(\mu|x)] = \int \frac{\mu}{c} e^{-\frac{11}{20}(\mu - \frac{10}{11}x)^2} d\mu = \frac{10}{11}x.$$



### Výhody Bayesovského přístupu

- a) Výpočet HPDR (High Posterior Density Region), kde  $\text{HPDR}(k) = \{\theta \in \Theta : \pi(\theta|\mathbf{x}) > k\}$  pro vhodnou konstantu  $k > 0$ .
- b) Zkoumání hypotézy  $H_0 : \theta \in \Theta_0$  vs.  $H_1 : \theta \notin \Theta_0$ . Máme k dispozici  $\mathbf{X}$  a k ní příslušnou statistiku  $T(\mathbf{X})$ , kde  $T(\mathbf{X}) \sim F_T$ . V klasické statistice bychom nyní testovali hypotézy na základě kritické oblasti  $W_\alpha = \{|T(\mathbf{X})| < K_\alpha\}$ . Nyní nám ale Bayesova věta říká, že pokud je  $\theta$  znáhodněný parametr, tak potom můžeme přímo vyjádřit pravděpodobnost (ať už apriorní, či aposteriorní), že platí  $H_0$ , a to následovně

$$\mathbb{P}^\pi(H_0) = \mathbb{P}^\pi(\theta \in \Theta_0), \quad \text{resp.} \quad \mathbb{P}^\pi(H_0|\mathbf{x}) = \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}),$$

jelikož na parametr  $\theta$  nahlížíme jako na náhodnou veličinu. Více se Bayesovskému testování bude věnovat poslední kapitola.

### 3 Další používané principy

Uvedené principy nejsou věty, ale něco, co chceme, aby platilo ve statistické proceduře (zatím ne Bayesovské).

**SUFFICIENCY princip:** Máme experiment  $\mathcal{E}$  závislý na  $\theta$ , pozorování  $x, y$  a nechť je v  $\mathcal{E}$  k dispozici postačující statistika  $T$  (PS). Víme-li, že  $T(x) = T(y)$ , chceme, aby závěry o  $\theta$  na základě  $x$  nebo  $y$  byly shodné. ( $T$  je PS, pokud rozdělení  $X|T(X) = t$  nezávisí na  $\theta$ ).

**LIKELIHOOD princip:** Informace o  $\theta$  nesená  $x$  je zcela obsažena ve věrohodnostní funkci  $L(\theta) = f_{\mathbf{X}}(\mathbf{x}, \theta)$ . Navíc, pokud máme pozorování  $x_1$  v experimentu  $\mathcal{E}_1$  a  $x_2$  v experimentu  $\mathcal{E}_2$  taková, že

$$L_1(\theta|x_1) = cL_2(\theta|x_2), \quad \forall \theta \in \Theta,$$

pak chceme, aby závěry o parametru  $\theta$  v obou experimentech byly shodné. Označíme to  $\text{Ev}(\mathcal{E}_1, x_1) = \text{Ev}(\mathcal{E}_2, x_2)$  (Ev jako Evidence).

**CONDITIONALITY princip:** Tento princip se od prvních dvou liší tím, že chceme, aby něco platilo pro všechna potenciálně naměřená data. Nechť máme dostupné  $\mathcal{E}_1, \mathcal{E}_2$ . Definujeme  $\mathcal{E}^*$  experiment tak, že vybereme náhodně mezi  $\mathcal{E}_1 \vee \mathcal{E}_2$  a v tom vybraném naměříme  $x_j$ ,  $j = 1 \vee 2$ . Chceme, aby  $\text{Ev}(\mathcal{E}^*, (j, x_j)) = \text{Ev}(\mathcal{E}_j, x_j)$ ,  $\forall j, \forall x_j$ . V prvním (složeném) experimentu tedy zaznamenáváme  $j \in \{0, 1\}$  jako index experimentu a  $x_j$  jako naměřenou hodnotu a chceme, aby závěr ze složeného experimentu byl stejný, jako kdyby nevybraný experiment vůbec neexistoval.

**STOPPING rule:** Máme posloupnost experimentů  $\mathcal{E}_1, \mathcal{E}_2, \dots$  a zastavovací pravidlo  $\tau$ , které zastavuje posloupnost v bodě  $\mathcal{E}_n$ . Jsou naměřeny  $\mathbf{x} = (x_1^{\mathcal{E}_1}, x_2^{\mathcal{E}_2}, \dots, x_n^{\mathcal{E}_n})$ . Chceme, aby  $\text{Ev}(\{\mathcal{E}_1, \dots, \mathcal{E}_n, \tau\}, \mathbf{x})$  závisela na  $\tau$  pouze prostřednictvím  $\mathbf{x}$ , tzn.

$$\text{Ev}(\{\mathcal{E}_1, \dots, \mathcal{E}_n, \tau_1\}, \mathbf{x}) = \text{Ev}(\{\mathcal{E}_1, \dots, \mathcal{E}_n, \tau_2\}, \mathbf{x}), \quad \forall \mathbf{x}.$$

**BAYESOVSKÝ princip:** Taková procedura, která využívá k rozhodnutí o parametru  $\theta$  aposteriorní hustotu  $\pi(\theta|\mathbf{x}) = \frac{f_{\mathbf{X}}(\mathbf{x}|\theta) \cdot \pi(\theta)}{\int f_{\mathbf{X}}(\mathbf{x}|\theta) \cdot \pi(\theta) d\theta}$ , např.  $\theta_B = \mathbb{E}[\pi(\theta, \mathbf{x})] = \mathbb{E}^\pi(\theta)$ .

**PŘÍKLAD 3.1.** Mějme  $\mathcal{E}_j \dots x_j \in \text{Ran}(X_j)$ , kde  $X_j \sim f(x_j, \theta)$ ,  $\forall j \in 1, 2, \dots$ . Teoreticky můžeme jít až do nekonečna, ale někdy chceme experiment zastavit, abychom mohli vyhodnotit data. Definujeme tedy  $\tau$  jako zastavení v bodě  $n$ , pokud

$$\mathbf{x} := (x_1, \dots, x_n) \in \text{Ran}(X_1) \times \text{Ran}(X_2) \times \dots \times \text{Ran}(X_n) \stackrel{\text{ozn}}{=} \mathcal{A}_n.$$

Platí, že

$$L(\theta|\mathbf{x}) \stackrel{id}{=} \left( \prod f_{X_j}(x_j, \theta) \right) \cdot I_{\mathcal{A}_n}(\mathbf{x}) \stackrel{\text{non id}}{=} f(x_1|\theta) f(x_2|x_1, \theta) \dots f(x_n|x_1, x_2, \dots, x_{n-1}, \theta) I_{\mathcal{A}_n}(\mathbf{x}).$$

Vidíme, že  $L(\theta|\mathbf{x})$  nezávisí na zastavovacím pravidlu  $\tau$  přímo, ale pouze prostřednictvím  $\mathbf{x}$ . Tedy pokud platí  $L$  princip, potom platí i  $SR$  princip.

**PŘÍKLAD 3.2.** Máme TV seriál. Označme  $\theta \in [0, 1]$  jako sledovanost daného dílu. Bylo zjištěno, že 9 diváků seriál sledují a 3 nikoliv (to jsou naše data). Problém je, že nevíme, jakým způsobem byla data naměřena.

### 3 Další používané principy

$\mathcal{E}_I$  : vybráno  $n = 12$  lidí, otestováno, získána data (9DIV,3NEDIV). Máme tedy náhodnou veličinu  $X$  jako počet diváků z  $n = 12$  nezávislých opakování. Z toho plyne, že  $X \sim \text{Bi}(12, \theta)$ . Máme napozorováno  $X(\omega) = x = 9$ .

$\mathcal{E}_{II}$  : vybíráme  $x$  osob a testujeme tak dlouho, dokud nezískáme 3 nediváky. Při tomto způsobu ale měření probíhá zcela odlišně. Tedy celkový počet otestovaných osob  $N \sim \text{NegBi}(3, 1 - \theta)$ . Napozorováno tedy bylo  $N(\omega) = n = 12$ .

Vidíme, že  $L_I(\theta, \mathcal{E}_I) = c_1 \theta^9 (1 - \theta)^3 \propto L_{II}(\theta, \mathcal{E}_{II}) = c_2 \theta^9 (1 - \theta)^3, \quad \forall \theta \in [0, 1]$ .

Pokud platí LIKELIHOOD princip, pak  $\text{Ev}(\mathcal{E}_I, (9)) = \text{Ev}(\mathcal{E}_{II}, (12))$  (takže vlastně na zastavovacím principu nezáleželo).

**PŘÍKLAD 3.3.** Máme laboratoř a v ní dva přístroje:

- 1. přístroj přesný  $X_1 \sim \mathcal{N}(\theta, 0.1)$  [ $\mathcal{E}_1$ ] (vytížený),
- 2. přístroj nepřesný  $X_2 \sim \mathcal{N}(\theta, 10)$  [ $\mathcal{E}_2$ ] (volný).

Rozhodování o  $\theta$ : 95%-interval spolehlivosti pro  $\theta$ .

A) osobně, naměříme  $x_1$  v  $\mathcal{E}$ , pak spočteme délku ( $IS_{95\%}$ ) = 0.62 (na 2. přístroji nezáviselo).

B) vyšleme laborantku, která nese data (ale neví, ze kterého přístroje jsou, prostě mohla použít i volný přístroj). Máme model  $\Phi = \beta \mathcal{N}(\theta, 0.1) + (1 - \beta) \mathcal{N}(\theta, 10)$ , kde  $\beta$  vyjadřuje míru obsazenosti 1. přístroje. Pak zjistíme  $x$  jako délku ( $IS_{95\%}$ ) s hodnotou 5.19.

**Věta 3.4.**  $S \wedge C \Leftrightarrow L \Rightarrow SR$ . Implikace  $L \Rightarrow C$  a  $L \Rightarrow S$  jsou důležité, protože  $B'' \Rightarrow L$ .

*Důkaz.*  $B'' \Rightarrow L$ : Mějme  $\mathcal{E}_1, \mathcal{E}_2, x_1, x_2$  a předpokládejme, že  $L_1(\theta) = cL_2(\theta)$ . Ptáme se, jestli je  $\text{Ev}(\mathcal{E}_1, x_1) = \text{Ev}(\mathcal{E}_2, x_2)$ . Víme, že

$$\underbrace{\pi_1(\theta|x_1)}_{\sim \mathcal{E}_1} = \frac{f_{X_1}(x_1|\theta)\pi(\theta)}{\int f_{X_1}(x_1|\theta)\pi(\theta)d\theta} = \frac{cf_{X_2}(x_2|\theta)\pi(\theta)}{\int cf_{X_2}(x_2|\theta)\pi(\theta)d\theta} = \underbrace{\pi_2(\theta|x_2)}_{\sim \mathcal{E}_2}.$$

$L \Rightarrow S$ : Nechť  $T$  je PS pro exponenciální  $\mathcal{E}$  a nechť máme data  $x_1^0, x_2^0$  (nula značí konkrétní výběr, nikoliv obecný), taková, že  $T(x_1^0) = T(x_2^0)$ . Máme k dispozici Neymannův faktorizační teorém,  $X \sim f(x, \theta)$ , pak  $T(X)$  je PS právě tehdy, když  $f(x|\theta) = h(x)g(T(x), \theta)$ ,  $\forall \theta$ . Potom tedy

$$L(\theta|x_1^0) = f(x_1^0, \theta) = h(x_1^0)g(T(x_1^0), \theta) = \frac{h(x_1^0)}{h(x_2^0)} \underbrace{h(x_2^0)g(T(x_2^0), \theta)}_{f(x_2^0, \theta) = L(\theta|x_2^0)}, \quad \forall \theta.$$

Z toho vyplývá (dle L principu), že  $\text{Ev}(\mathcal{E}, x_1^0) = \text{Ev}(\mathcal{E}, x_2^0)$ .

$L \Rightarrow C$ : Uvažujeme experiment  $\mathcal{E}^*$  tak, že  $(I, X_I) = X^*, I = 1 \vee 2, X_I = x_1 \vee x_2$ . Dále potom

$$\begin{aligned} L^*(\theta|(j, x_j)) &= \mathbb{P}(X^* = (j, x_j)) = \mathbb{P}(I = j \wedge X_{I=j} = x_j) = \mathbb{P}(I = j)\mathbb{P}(X_j = x_j) = \\ &= 0.5f(x_j, \theta) = 0.5L_j(\theta, x_j) \end{aligned}$$

pro  $\forall \theta, \forall x_j$ , tzn.  $L^* = cL_j$ . Potom tedy dle Likelihood principu máme

$$\text{Ev}(\mathcal{E}^*, (j, x_j)) = \text{Ev}(\mathcal{E}_j, x_j), \quad \forall j, \forall x_j.$$

□

## 4 Třídy optimálních strategií, užitková funkce

### 4.1 Statistical decision theory

**Definice 4.1.** Označíme  $\mathcal{D}'$  jako množinu možných rozhodnutí o  $\theta$ , případně  $\tau(\theta)$ . Dále potom  $d \in \mathcal{D}'$  je rozhodnutí.  $L : \Theta \times \mathcal{D}' \rightarrow [0, +\infty)$  nazýváme **loss function** (ztrátová funkce) a  $L(\theta, d)$  je **míra ztráty** (shody, neshody), pokud pro  $\theta$  použijeme rozhodnutí  $d$ .

Označme dále  $\mathcal{R}$  jako **reward space**, který je spojen s  $\mathcal{D}'$ , tj.  $\forall d \in \mathcal{D}'$  přiřazujeme  $r \in \mathcal{R}$  ( $d \leftrightarrow r$ ). Předpokládejme dále, že na  $\mathcal{R}$  existuje úplné uspořádání ( $\leq$ ) tak, že

A1)  $\forall r_1, r_2 \in \mathcal{R}, r_1 \leq r_2 \vee r_2 \leq r_1$ ,

A2)  $\forall r_1, r_2, r_3 \in \mathcal{R}, r_1 \leq r_2 \wedge r_2 \leq r_3 \Rightarrow r_1 \leq r_3$ .

Z toho vyplývá, že nastává právě jedna varianta

$$r_1 < r_2, \quad r_2 < r_1, \quad r_1 = r_2 \quad (r_1 \sim r_2).$$

Poslední rovnost není myšlena jako číselná rovnost, ale spíše jako ekvivalence (peníze pro nás můžou mít stejnou cenu, jako získané znalosti).

Nad  $\mathcal{R}$  definujeme prostor  $\mathcal{P}$  pravděpodobnostních distribucí náhodné veličiny  $r$  ( $r \sim \mathbb{P} \in \mathcal{P}$ ). Předpokládejme, že na  $\mathcal{P}$  existuje úplné uspořádání ( $\leq$ ) analogické s A1) a A2) (jinými slovy zvolíme způsob, jakým lze uspořádat pravděpodobnosti, třeba jak moc se odchyľují od rovnoměrného rozdělení apod.).

**PŘÍKLAD 4.2** (Motivace). Označme  $d_i$  jako investice do  $i$ -té společnosti. Na konci roku pak očekáváme dividendy  $r_i$ . Máme tedy  $(d_i)_1^k, (r_i)_1^k$  a celková dividendy  $r = \sum_{i=1}^n r_i$  pak mají rozdělení  $\mathbb{P} = \mathbb{P}_1 * \dots * \mathbb{P}_k$  (konvoluce, protože sčítáme náhodné veličiny), které lze aproximovat z CLT.

**Definice 4.3.** Funkci  $U$  na  $\mathcal{R}$  nazveme **užitkovou** (utility function), pokud  $\forall P, Q \in \mathcal{P}$  platí, že

$$P \leq Q \Leftrightarrow \mathbb{E}^P[U(r)] \leq \mathbb{E}^Q[U(r)],$$

kde  $r$  je náhodná veličina. Pokud to jde, můžeme například volit  $U(r) = r$ .

**POZNÁMKA 4.4.** Pokud má  $\mathcal{P}$  vhodné vlastnosti, pak existuje užitková funkce  $U(r)$ , která zachovává dané uspořádání  $\mathcal{P}$ , a pro ztrátu  $L(\theta, d) \geq 0$  můžeme volit  $L(\theta, d) = U(\theta, d) = -\mathbb{E}[U(r)] + c$ , kde konstantu  $c$  přičítáme proto, abychom se nedostali do záporných čísel. Tím zajistíme, že pokud budeme provádět minimalizaci  $L$ , pak provádíme i maximalizaci užitku.

**PŘÍKLAD 4.5** (volba L). Předpověď počasí v Kanadě. Předpovědi jsou ve tvaru "pravděpodobnost, že zítra bude pršet je  $p$ ". Předpovědi od různých společností chceme nějak porovnat. Sledujeme tedy 365 dní všechny předpovědi a přiřadíme každému předpovídateli jeho použitá  $p_1, \dots, p_N$ , kde  $N$  je počet různých procentuálních předpovědí v daném roce (tedy  $N \leq 365$ ). Definujeme relativní četnost

$$\theta_j = \frac{\# \text{ dnů, kdy pršelo a byla použita } p_j}{\# \text{ dnů, kdy byla použita } p_j}, \quad j \in \hat{N}.$$

Sestavíme ztrátovou funkci (použil De Groot v roce 1988)

$$L(\theta, \mathbf{p}) = \sum_{j=1}^N q_j (p_j - \theta_j)^2 + \sum_{i=1}^N q_i \ln q_i,$$

#### 4 Třída optimálních strategií, užitková funkce

kde  $q_j = \frac{\# \text{ použití } p_j}{365}$  a  $H(\mathbf{q}) = -\sum_1^N q_j \ln q_j \geq 0$  je entropie rozdělení  $\{q_j\}_{j=1}^N$ . Suma  $\sum_{i=1}^N q_i \ln q_i$  pak penalizuje předpovědi, které jsou nevyvážené, protože pro systém neuspořádanosti (rovněžné rozdělení  $q_j = \frac{1}{N}$ ,  $\forall j$ ) je  $H(\mathbf{q})$  maximální.

Člen  $\sum_{j=1}^n q_j (p_j - \theta_j)^2$  nemusí být nutně na druhou, můžeme brát závorku i v absolutní hodnotě, případně ji umocnit na  $\alpha \in (0, 2)$  a regulovat tak robustnost  $L(\theta, p)$ . Tím vším vstupuje do našeho problému tzv. **Apriorio**, musíme totiž dopředu vědět některé informace, třeba  $X \sim f(x, \theta)$ , tvar  $L(\theta, d)$ .

## 5 Rozhodovací principy statistiky

Zatím tedy máme 3 prostory, výběrový prostor  $\chi = \{\mathbf{x}\}$  pro data  $\mathbf{x}$ , parametrický prostor  $\Theta = \{\theta\}$ , rozhodovací prostor  $\mathcal{D}' = \{d\}$  a definujeme na nich několik věcí.

**Definice 5.1.** Mějme  $\chi, \Theta, \mathcal{D}'$  a prostor  $\mathcal{F} = \{f(x|\theta) : \theta \in \Theta\}$ . Funkci  $\delta : \chi \rightarrow \mathcal{D}'$  nazýváme **rozhodovací funkce** a platí, že  $\delta(\mathbf{x}) = d \in \mathcal{D}'$ , kde  $\delta \in \mathcal{D}$  jako prvek prostoru rozhodovacích funkcí. Rozhodovací funkce nám tedy říká, jaké rozhodnutí uděláme na základě dat  $\mathbf{x}$ .

### 5.1 Metoda A) minimalizace L:


$\delta_L(\mathbf{x}) = \underset{\delta \in \mathcal{D}}{\operatorname{argmin}} L(\theta, \delta(\mathbf{x})), \forall \theta \in \Theta, \forall \mathbf{x} \in \chi$ . Avšak je obtížné, až nemožné, takto obecně stejnoměrně minimalizovat.

### 5.2 Metoda B) minimalizace $\mathbb{E}L$

Stejněměrná minimalizace má spoustu problémů (ne vždy to jde). Pokud se jich chceme zbavit, můžeme například minimalizovat střední ztrátu. Použijeme k tomu rizikovou funkci (risk function)  $\mathcal{R} : \Theta \times \mathcal{D}' \rightarrow \mathbb{R}^+$ , definovanou jako

$$\mathcal{R}(\theta, \delta) = \mathbb{E}_\theta L(\theta, \delta(\mathbf{X})) = \int_\chi L(\theta, \delta(\mathbf{x})) f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x}.$$

Rizikovou funkci také nazýváme jako *střední ztrátu*. Definujeme  $\delta_U = \underset{\delta \in \mathcal{D}}{\operatorname{argmin}} \mathcal{R}(\theta, \delta), \forall \theta \in \Theta$ .



Obrázek 5.1: HPD Region (Highest Posterior Density). Pokud by nějaká funkce  $\mathcal{R}(\theta, \delta_6)$  náhodou na nějakém intervalu byla menší, než  $\mathcal{R}(\theta, \delta_5)$ , tak bychom ji jednoduše zahodili.

Ne vždy lze najít stejnoměrně nejlepší řešení. V takovém případě pak přejdeme na prostor  $\mathcal{D}_0 \subset \mathcal{D}$ , kde již lze najít stejnoměrně nejlepší řešení (typicky vypustíme některé rizikové funkce), viz 5.1. Můžeme tedy optimalizovat na různých prostorech rozhodovacích funkcí, např.

a) Prostor rozhodovacích funkcí, které jsou nestranné – pak vede na UMVUE.

- b)  $\mathcal{D}'_0$  takový, který je prostorem ekvivariantních rozhodovacích funkcí na modelech invariantních na určitou transformaci (např. posunutí, přeskálování, tzn. tzv. **lokálně-měřítkové modely**).

Problémy této stejnoměrně optimální strategie:

- a)  $\delta_1, \delta_2$  a k nim  $\mathcal{R}(\theta, \delta_1), \mathcal{R}(\theta, \delta_2)$  takové, že se kříží – nejsme schopni rozhodnout, která strategie je lepší.  
 b) Minimalizujeme  $\mathbb{E}L$ , ale  $\delta$  nezávisí na  $\mathbf{x}$ , tedy výběr nejlepšího  $\delta$  nezávisí na naměřených datech.  
 c) Na rozmyšlenou je příklad 5.2.

**PŘÍKLAD 5.2.** Mějme  $X = \begin{cases} \theta - 1, & \mathbb{P} = \frac{1}{2}, \\ \theta + 1, & \mathbb{P} = \frac{1}{2}, \end{cases} \theta \in \mathbb{R}, \mathcal{D}' = \mathbb{R}$ . Volme  $L(\theta, d) = 1 - I_\theta(d)$ , kde  $I_\theta(d)$  je 1, pokud  $d = \theta$  a nula, pokud ne (nazýváme ji "0-1" ztrátovou funkcí).

- 1) Máme  $\mathbf{x} = (x_1, x_2)$  data a sestrojíme  $\delta_0(\mathbf{x}) = \frac{x_1 + x_2}{2} = \begin{cases} \theta \\ \theta - 1 \\ \theta + 1 \end{cases}$  symetricky kolem  $\theta$ .

Potom

$$\mathcal{R}(\theta, \delta_0) = \mathbb{E}L(\theta, \delta_0(\mathbf{X})) = 1 - \mathbb{E}I_\theta(\delta_0(\mathbf{X})) = 1 - \mathbb{P}(\delta_0(\mathbf{X}) = \theta) = 1 - \mathbb{P}(X_1 = X_2) = \frac{1}{2}.$$

To nám říká, že střední ztráta je rovna  $\frac{1}{2}$ , tzn. že v průměru 50% případů bude příznivých (trefíme se do parametru).

- 2) Máme data  $\mathbf{x} = (x_1, x_2)$  a sestrojíme  $\delta_1(\mathbf{x}) = x_1 + 1 = \begin{cases} \theta \\ \theta + 2 \end{cases}$  nesymetricky rozdělené kolem  $\theta$ . Potom

$$\mathcal{R}(\theta, \delta_1) = \dots = 1 - \mathbb{P}(\delta_1(\mathbf{X}) = \theta) = 1 - \mathbb{P}(X_1 = \theta - 1) = \frac{1}{2}.$$

Srovnání  $\delta_0$  a  $\delta_1$  nelze rozhodnout na základě  $\mathcal{R}$ -strategie.


### 5.3 Metoda C) Strategie MINIMAXní

**Definice 5.3.** Mějme  $\delta \in \mathcal{D}$ . Potom definujeme  $\mathcal{R}_{\sup}(\theta, \delta) := \sup_{\theta \in \Theta} \mathcal{R}(\theta, \delta) \in \mathbb{R}^+$  jako "maxní" (supremální) rizikovou funkci. Definujeme dále

$$\delta_0 = \operatorname{argmin}_{\delta \in \mathcal{D}} \mathcal{R}_{\sup}(\theta, \delta) = \operatorname{argmin}_{\delta \in \mathcal{D}} \sup_{\theta \in \Theta} \underbrace{\mathbb{E}_\theta L(\theta, \delta(\mathbf{X}))}_{\mathcal{R}(\theta, \delta)}.$$

**Definice 5.4.** Definujeme **minimaxní riziko** jako  $\overline{\mathcal{R}} = \inf_{\delta \in \mathcal{D}} \sup_{\theta \in \Theta} \mathcal{R}(\theta, \delta)$ .

**POZNÁMKA 5.5.** Analogie z teorie her. Máme 2 hráče, kteří mají antagonický vztah (snaží se navzájem poškodit a nezáleží jim na ztrátě). První hráč udělá nějaký tah. Druhý hráč pak udělá tah, který co nejvíc poškodí 1. hráče. První hráč to předvídá a snaží se tedy minimalizovat nejhorší možnou ztrátu.



Obrázek 5.2: 1: zeleně suprema, nejmenší supremum je pro  $\delta_2$ , 2: lepší je  $\delta_2$ , protože ač je riziko vysoké, jeho šance je velice malá - toto je nevýhoda minimaxní strategie 3:  $\delta_2$  jen lehce překmitne  $\delta_1$  a pak se k němu blíží asymptoticky

## 5.4 Metoda D) Bayesovská riziková funkce

**Definice 5.6.** Necht  $\Pi = \{\pi\}$  je množina všech apriorních rozdělení pro parametr  $\theta$ . Definujeme **Bayesovskou rizikovou funkci**  $r : \Pi \times \mathcal{D} \rightarrow \mathbb{R}_0^+$  vztahem

$$r(\pi, \delta) := \mathbb{E}^\pi[\mathcal{R}(\theta, \delta)] = \int_{\Theta} \mathcal{R}(\theta, \delta) \pi(\theta) d\theta = \int_{\Theta} \left( \int_{\mathcal{X}} L(\theta, \delta(\mathbf{X})) f_{\mathbf{X}}(\mathbf{x}|\theta) d\mathbf{x} \right) \pi(\theta) d\theta.$$

Definujeme dále **Bayesovskou rozhodovací funkci**, za předpokladu existence, jako

$$\delta^\pi := \operatorname{argmin}_{\delta \in \mathcal{D}} r(\pi, \delta).$$

Číslo  $r(\pi) := r(\pi, \delta^\pi)$  nazýváme **Bayesovské (apriorní) riziko**.

**POZNÁMKA 5.7.** Mějme  $\pi$  fixní. Pak  $\delta_1 \leq \delta_2$  právě tehdy, když  $r(\pi, \delta_1) \leq r(\pi, \delta_2)$  jsou uspořádané v  $\mathbb{R}^1$ . To lze rozšířit i na nevlastní apriorní hustoty (informace), ale pouze pokud  $r(\pi) < +\infty$ .

**PŘÍKLAD 5.8.** Mějme  $X \sim \underbrace{\mathcal{N}(\theta, 1)}_{f_X(x|\theta)}$ ,  $\theta \in \mathbb{R}$ ,  $\pi(\theta) = 1$  (konstantní) na  $\mathbb{R}$  (nevlastní hustota, tedy nepreferujeme dopředu žádnou hodnotu). Pak

$$\pi(\theta|x) = \frac{f_X(x|\theta)\pi(\theta)}{\int_{-\infty}^{+\infty} f_X(x|\theta)\pi(\theta)d\theta} = \frac{1}{c} e^{-\frac{1}{2}(\theta-x)^2} = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\theta-x)^2} = \mathcal{N}(x, 1).$$

$$\delta^\pi(x) = \mathbb{E}[\pi(\theta|x)] = \mathbb{E}\mathcal{N}(x, 1) = x,$$

$$\begin{aligned} r(\pi) &= r(\pi, \delta^\pi) = \mathbb{E}^\pi \mathcal{R}(\theta, \delta^\pi) = \mathbb{E}^\pi [\mathbb{E}^f L_2(\theta, \delta^\pi(X))] \stackrel{\text{def}}{=} \mathbb{E}^\pi [\mathbb{E}^f (\theta - \delta^\pi(X))^2] = \mathbb{E}^\pi \mathbb{E}^f (\theta - X)^2 = \\ &= \mathbb{E}^\pi [\mathbb{E}^f (X - \mathbb{E}^f X)^2] = \mathbb{E}^\pi (\sigma^2) = \int_{-\infty}^{+\infty} \sigma^2 \cdot \underbrace{\pi(\theta)}_1 d\theta = +\infty. \end{aligned}$$

**Definice 5.9.** Máme  $L$ ,  $f_{\mathbf{X}}$ ,  $\pi(\theta)$ . Definujeme **aposteriorní Bayesovskou rizikovou funkci** vztahem

$$\varrho(\pi, \delta|\mathbf{x}) := \mathbb{E}^\pi [L(\theta, \delta(\mathbf{x})) | \mathbf{X} = \mathbf{x}] = \int_{\Theta} L(\theta, \delta(\mathbf{x})) \pi(\theta|\mathbf{x}) d\theta.$$

**Definice 5.10** (Metoda E) nic nového). Definujeme-li  $\delta_\varrho^\pi(\mathbf{x}) := \operatorname{argmin}_{\delta} \varrho(\pi, \delta|\mathbf{x})$  za předpokladu existence pro skoro všechna  $\mathbf{x}$ , pak tato riziková funkce splývá s Bayesovskou rozhodovací funkcí  $\delta^\pi$ .



## 5 Rozhodovací principy statistiky

POZNÁMKA 5.11. Výhoda této definice je, že  $\delta_\rho^\pi$  závisí přímo na datech  $\mathbf{x}$ . Nevýhoda pak je, že musíme minimalizaci dělat opakovaně pro každá data  $\mathbf{x}$ .

**Věta 5.12.** Máme-li  $\delta_\rho^\pi$  pro s.v.  $\mathbf{x}$ , pak  $\delta_\rho^\pi = \delta^\pi$ , tj. je rovna s.v. Bayesovské rizikové funkci  $\delta^\pi = \operatorname{argmin}_\delta r(\pi, \delta)$  podle D strategie.

*Důkaz.*

$$\begin{aligned} \varrho(\pi, \delta_\rho^\pi(\mathbf{x})|\mathbf{x}) &\leq \varrho(\pi, \delta(\mathbf{x})|\mathbf{x}) \text{ pro s.v. } \mathbf{x}, \text{ což víme z definice. Potom ale} \\ \mathbb{E}^m \varrho(\pi, \delta_\rho^\pi(\mathbf{x})|\mathbf{x}) &\leq \mathbb{E}^m \varrho(\pi, \delta(\mathbf{x})|\mathbf{x}), \text{ kde } m(\mathbf{x}) = \int_{\Theta} f(\mathbf{x}|\theta) \cdot \pi(\theta) d\theta. \end{aligned}$$

Nyní rozepíšeme pravou stranu (potom to uděláme i s levou)

$$\begin{aligned} \mathbb{E}^m \varrho(\pi, \delta(\mathbf{x})|\mathbf{x}) &= \int_{\mathcal{X}} \left( \int_{\Theta} L(\theta, \delta) \underbrace{\pi(\theta|\mathbf{x})}_{\frac{f(\mathbf{x}|\theta)\pi(\theta)}{\int f(\mathbf{x}|\theta)d\theta} = \frac{f(\mathbf{x}|\theta)}{m(\mathbf{x})}} d\theta \right) m(\mathbf{x}) d\mathbf{x} \stackrel{\text{Fubini}}{=} \int_{\Theta} \left( \int_{\mathcal{X}} L(\theta, \delta(\mathbf{x})) f(\mathbf{x}|\theta) d\mathbf{x} \right) \pi(\theta) d\theta = \\ &= \mathbb{E}^\pi \mathbb{E}^f L = r(\pi, \delta). \end{aligned}$$

$$\mathbb{E}^m \varrho(\pi, \delta_\rho^\pi(\mathbf{x})|\mathbf{x}) = \{\text{Analogický postup}\} = r(\pi, \delta_\rho^\pi).$$

A tedy

$$r(\pi, \delta_\rho^\pi) \leq r(\pi, \delta), \quad \forall \delta \quad \Rightarrow \quad \delta_\rho^\pi = \delta^\pi.$$

Závěr: D strategie Bayes ( $\delta^\pi$ ) je rovna E strategii Bayes ( $\delta_\rho^\pi(\mathbf{x})$  pro s.v.  $\mathbf{x}$ ). □

Rozšíření: Máme-li  $\delta_\rho^\pi(\mathbf{x})$  pro s.v.  $\mathbf{x}$  a stane se, že  $r(\pi) = +\infty$ , pak toto řešení  $\delta^\pi$  nazveme **Zobecněnou Bayesovskou rozhodovací funkcí**.

## Postup při aplikaci Bayesovské strategie

Můžeme postupně iterovat přes nová data. Na začátku máme znalosti o parametru  $\theta$  z minulosti v podobě  $\pi(\theta)$  a nově naměříme data  $\mathbf{X} \sim f(\mathbf{x}|\theta)$ . Za pomoci úplného Bayesovského modelu můžeme updatovat naše znalosti, přičemž získáme  $\pi(\theta|\mathbf{x})$ . Z toho můžeme například odhadnout  $\hat{\theta}_B$ , případně interval spolehlivosti apod. Poté nová data označíme za aktuální (aposteriorní hustotu přeznačíme na apriorní) a pokračujeme dále, tedy  $\tilde{\pi}(\theta) = \pi(\theta|\mathbf{x})$ . Následně získáme nová data  $\tilde{\mathbf{X}} \sim \tilde{f}(\tilde{\mathbf{x}}|\theta)$  a získáme  $\tilde{\pi}(\theta|\tilde{\mathbf{x}})$ ...

## 5.5 Úloha predikce

Zkusme porovnat klasickou a Bayesovskou statistiku v úloze predikce.

### Klasická statistika

Předpokládáme  $X \sim f(x, \theta)$ , aniž bychom měli apriorní informaci, a naměříme data  $\mathbf{x} = (x_1, \dots, x_n)$  jako realizaci  $\mathbf{X} = (X_1, \dots, X_n)$ . Hledáme predikci (realizaci)  $X_{n+1}$ . Pokud jsou  $X_1, \dots, X_n$  iid, pak  $X_{n+1} \sim f(x, \theta)$  a stačí nám najít příslušné rozdělení. Proto zkusíme najít odhad závislý na  $\mathbf{x}$  ve tvaru  $\hat{\theta} = \theta(\mathbf{x}) = \theta_{ML}$ . Z toho pak získáme  $\hat{f}(x) = f(x, \hat{\theta}_{ML})$  a z toho  $X_{n+1} \sim \hat{f}(x)$ .

**Bayesovská statistika**

Opět máme  $X \sim f(x|\theta)$ , data  $\mathbf{x}$  a navíc apriorní informaci  $\pi(\theta)$ . Máme několik možností jak pokračovat.

- a) Z toho vypočítáme  $\pi(\theta|\mathbf{x})$  a z toho získáme odhad  $\hat{\theta}_B = \mathbb{E}[\pi(\theta|\mathbf{x})]$ . Následně určíme hustotu  $\hat{f}(x) = f(x|\hat{\theta}_B)$  a pokračujeme klasicky s odhadem  $X_{n+1} \sim \hat{f}$ . Bayes obecně není invariantní na tranformace, takže nemůžeme říct, že jsme získali Bayesovský odhad hustoty.
- b) Můžeme také zkusit odhadnout přímo celou hustotu  $\tau(\theta) = f(x|\theta)$ , kde za použití apriorní hustoty  $\pi(\theta)$  získáme  $\hat{f}_B(x) = \widehat{\tau_B(\theta)}$ . Následní můžeme predikovat  $X_{n+1}$  jako  $X_{n+1} \sim \hat{f}_B$ .
- c)

**Definice 5.13.** Máme ÚBM (Úplný Bayesovský model) pro  $\mathbf{X} \sim f_{\mathbf{X}}(\mathbf{x}|\theta)$ , apriorní hustotu  $\pi(\theta)$  a posteriorní hustotu  $\pi(\theta|\mathbf{x})$ . Pak definujeme **Bayesovskou prediktivní hustotu**  $f_B^{PR}$  vztahem

$$f_B^{PR}(t|\mathbf{x}) = \int_{\Theta} f_X(t|\theta)\pi(\theta|\mathbf{x})d\theta = \mathbb{E}^{\pi}[f_X(t|\theta)|\mathbf{x}].$$

Potom  $X_{n+1} \sim f_B^{PR}(x_{n+1}|\mathbf{x})$ , z čehož můžeme predikovat

$$\mathbb{P}(X_{n+1} > b) = \int_b^{+\infty} f_B^{PR} dx_{n+1}.$$

Výhodou c) je to, že obsahuje "plnou" (ve smyslu integrálu) informaci posteriorní hustoty  $\pi(\theta|\mathbf{x})$ .

## 6 Asymptotické vlastnosti aposteriorní hustoty a Bayesovských bodových odhadů

**Definice 6.1.** Mějme  $P, Q \in \mathcal{P}$  a definujeme **totální variaci**  $\text{TV}(P, Q) = \|P - Q\|_{\text{TV}} = \sup_{|g| \leq 1} \left| \int g(\mathbf{X}) dP - \int g(\mathbf{Y}) dQ \right| \stackrel{\text{ASR}}{=} \left| p \stackrel{\text{ozn}}{=} \frac{dP}{d\mu} \quad P, Q \ll \mu \quad q = \frac{dQ}{d\mu} \right| = \int |p - q| d\mu = \|p - q\|_{L_1}$ .

**Definice 6.2.** Mějme posloupnost měr  $(P_n)_1^{+\infty}$  a limitní míru  $Q$ . Řekneme, že  $P_n$  konverguje silně ke  $Q$ , značíme  $P_n \xrightarrow{s} Q$ , pokud  $\text{TV}(P_n, Q) \rightarrow 0$ .

POZNÁMKA 6.3. Připomenutí slabé konvergence

$$P_n \xrightarrow{w} Q \Leftrightarrow \int g(\mathbf{X}) dP_n \rightarrow \int g(\mathbf{Y}) dQ, \quad \forall g \in C_B^{(0)} \text{ spojitě a omezené.}$$

**Věta 6.4.**  $P_n \xrightarrow{s} Q \Rightarrow P_n \xrightarrow{w} Q$  (AN).

*Důkaz.* Nechť funkce  $g$  je spojitá a omezená,  $|g| \leq M$ ,  $g^* = \frac{g}{M}$ ,  $|g^*| \leq 1$ . Pak

$$\left| \int g(\mathbf{X}) dP_n - \int g(\mathbf{Y}) dQ \right| = M \left| \int g^*(\mathbf{X}) dP_n - \int g^*(\mathbf{Y}) dQ \right| \leq M \cdot \|P_n - Q\|_{\text{TV}} \xrightarrow{\text{LDCT}} 0.$$

□

**Věta 6.5** (Scheffé theorem). Mějme  $P_n, Q$  s  $\text{ASR}_\mu$ ,  $p_n = \frac{dP_n}{d\mu}$ ,  $q = \frac{dQ}{d\mu}$ . Nechť dále hustota pravděpodobnosti  $p_n \rightarrow q$  s.j.  $\mu$ . Pak  $P_n \xrightarrow{s} Q$ .

*Důkaz.*

$$\left| \int_A (p_n - q) d\mu \right| \leq \int_A |p_n - q| d\mu \leq \int_{\mathbb{R}} |p_n - q| d\mu = 2 \int (p_n - q)^+ d\mu \rightarrow 0,$$

kde poslední rovnost platí, protože  $\int (p_n - q) d\mu = 0$ , a tedy  $\int (p_n - q)^+ d\mu - \int (p_n - q)^- d\mu = 0$ . □

POZNÁMKA 6.6. Z 01MAS víme, že pro  $\mathcal{F}_{\text{reg}}^{\text{MLE}}$  platí, že

- 1)  $\text{supp } f$  nezávisí na  $\theta$ ,
- 2)  $f \in \mathcal{C}^{(3)}$  vzhledem k  $\theta$  pro s.v.  $x \in \text{supp } f$ ,
- 3)  $\int f'_\theta = 0$  a  $\int f''_{\theta\theta} = 0$ ,
- 4)  $(\mathbb{I}(\theta))_{i,j} = \mathbb{E} \left[ \frac{\partial \log f}{\partial \theta_i} \cdot \frac{\partial \log f}{\partial \theta_j} \right] = -\mathbb{E} \left[ \frac{\partial^2 \log f}{\partial \theta_i \partial \theta_j} \right]$ ,  $\mathbb{I}(\theta)$  je PD a konečná pro  $\forall \theta \in \Theta$ ,
- 5)  $\forall \theta_0 \exists H_{\theta_0} \exists M(\mathbf{X}) \in \mathcal{L}_1(P_{\theta_0})$  tak, že  $\left\| \frac{\partial^3 \log f}{\partial \theta^3} \right\| \leq M(x)$  na  $H_{\theta_0}$ , kde  $\mathbb{E}_{\theta_0}[M(X)] < +\infty$ .

**Věta 6.7** (Bernstein - von Mises). Předpokládejme ÚBM,  $X \sim f(x|\theta)$  vzhledem k míře  $\lambda$ , která je  $\sigma$ -finitní,  $\mathcal{F} = \{f(x|\theta) : \theta \in \Theta \subset \mathbb{R}^k\}$ ,  $\Theta$  otevřená,  $\theta \sim \pi(\theta)$  vlastní hustota, spojitá a  $\pi(\theta) > 0$  (Tedy máme  $\varphi(x, \theta) = f \cdot \pi$ ,  $m(\mathbf{x}) = \int f \cdot \pi d\theta$ ,  $\pi(\theta|\mathbf{x}) = \varphi/m = \frac{f \cdot \pi}{\int f \cdot \pi d\theta}$ ). Nechť dále  $\mathcal{F} = \mathcal{F}_{\text{reg}}^{\text{MLE}}$ . Pak

$$\left\| \pi(\theta|\mathbf{x}) - f_{\mathcal{N}(\hat{\theta}_n, \frac{1}{n} \mathbb{I}^{-1}(\theta_0))} \right\|_{TV} \rightarrow 0 \quad \text{pro } \forall \theta_0,$$

kde  $\hat{\theta}_n$  je konzistentní řešení  $LE_Q$ , tzn.  $\hat{\theta}_n$  řeší  $\frac{\partial \log f}{\partial \theta_j} = 0$ ,  $\forall j \in \hat{k}$ .

## 6 Asymptotické vlastnosti aposteriorní hustoty a Bayesovských bodových odhadů

**Důsledek 6.8.** Mějme  $\mathcal{F}_{reg}^{MLE}$ ,  $\pi(\theta) > 0$  vlastní hustota a spojitá,  $\theta_0$  skutečná hodnota parametru  $\theta$ . Pak  $(\theta|\mathbf{x}) \sim \mathcal{AN}(\hat{\theta}_n(\mathbf{x}), \frac{1}{n}\mathbb{I}^{-1}(\theta_0))$  pro  $\forall \theta_0$ .

Závěr:  $\sqrt{n}((\theta|\mathbf{x}) - \hat{\theta}_n(\mathbf{x})) \xrightarrow{\mathcal{D}} \mathcal{N}(0, \mathbb{I}^{-1}(\theta_0))$ ,  $\forall \theta_0$ . Bayesovská strategie je asymptoticky ekvivalentní MLE.

Důkaz.  $k = 1$ : Máme  $f_X$ ,  $(X_j)_1^n$ ,  $f_{X_j}(x_j|\theta)$ ,  $f_n \stackrel{id}{=} \prod_1^n f_{X_j} = f_n(\mathbf{x}|\theta)$ ,  $\pi(\theta|\mathbf{x}) = \frac{f_n \pi}{\int f_n \pi d\theta}$ . Transformujeme pomocí  $g : t = \sqrt{n}(\theta|\mathbf{x} - \hat{\theta}_n)$ , kde  $\hat{\theta}_n$  je ELE (konzistentní řešení  $LE_Q$ ),  $g^{-1} : \theta|\mathbf{x} = \hat{\theta}_n + \frac{t}{\sqrt{n}}$ ,  $\mathbb{J}_{g^{-1}} = \frac{1}{\sqrt{n}} > 0$ . Potom transformujeme

$$\begin{aligned} \theta|\mathbf{x} &\sim \pi(\theta|\mathbf{x}), \\ \sqrt{n}(\theta|\mathbf{x} - \hat{\theta}_n) &\sim \frac{f_n(\mathbf{x}|\hat{\theta}_n + \frac{t}{\sqrt{n}})\pi(\hat{\theta}_n + \frac{t}{\sqrt{n}})(\frac{1}{\sqrt{n}})}{\int f_n(\mathbf{x}|\theta)\pi(\theta)d\theta} = \left| \begin{array}{l} \theta = \hat{\theta}_n + \frac{s}{\sqrt{n}} \\ d\theta = \frac{ds}{\sqrt{n}} \end{array} \right| = \\ &= \frac{f_n(\mathbf{x}|\hat{\theta}_n + \frac{t}{\sqrt{n}})\pi(\hat{\theta}_n + \frac{t}{\sqrt{n}})}{\int f_n(\mathbf{x}|\hat{\theta}_n + \frac{s}{\sqrt{n}})\pi(\hat{\theta}_n + \frac{s}{\sqrt{n}})ds}. \end{aligned}$$

Máme spojitě  $\partial_\theta^3$ , a proto rozvineme pomocí Taylora  $\log f_n$  do 2. řádu:

$$\begin{aligned} \log f_n(\mathbf{x}|\hat{\theta}_n + \frac{t}{\sqrt{n}}) &= \log f_n(\mathbf{x}|\hat{\theta}_n) + 0^* + \frac{1}{2} \frac{t^2}{n} \frac{\partial^2 \log f_n}{\partial \theta^2} \Big|_{\theta=\hat{\theta}_n} + R_n = \\ &= \log f_n(\mathbf{x}|\hat{\theta}_n) + \frac{t^2}{2} \underbrace{\left( \frac{1}{n} \sum_{j=1}^n \frac{\partial^2 \log f_{X_j}(x_j|\hat{\theta}_n)}{\partial \theta^2} \right)}_{\substack{\xrightarrow[\text{ZVČ}]{\mathbb{P}_{\theta_0}} \mathbb{E} \left[ \frac{\partial^2 \log f_X}{\partial \theta^2} \right] = -\mathbb{I}(\hat{\theta}_n) \wedge \hat{\theta}_n \xrightarrow{\mathbb{P}_{\theta_0}} \theta_0}} + \underbrace{R_n}_{\substack{\xrightarrow[\text{(s.j.)}]{\mathbb{P}_{\theta_0}} 0}}. \end{aligned}$$

Z toho potom plyne, že  $f_n(\mathbf{x}|\hat{\theta}_n + \frac{t}{\sqrt{n}}) = f_n(\mathbf{x}|\hat{\theta}_n) e^{-\frac{t^2}{2} \mathbb{I}(\hat{\theta}_n)} \cdot \tilde{R}_n$  a tedy

$$\begin{aligned} \pi(t|\mathbf{x}) &= \frac{f_n e^{-\frac{t^2}{2} \mathbb{I}(\hat{\theta}_n)} \cdot \tilde{R}_n \pi(\hat{\theta}_n + \frac{t}{\sqrt{n}})}{f_n \int e^{-\frac{s^2}{2} \mathbb{I}(\hat{\theta}_n)} \tilde{R}_n \pi(\hat{\theta}_n + \frac{s}{\sqrt{n}}) ds} \xrightarrow{(n \rightarrow \infty)} \frac{e^{-\frac{t^2}{2} \mathbb{I}(\theta_0)} \cdot 1 \cdot \pi(\theta_0)}{\int e^{-\frac{s^2}{2} \mathbb{I}(\theta_0)} \cdot 1 \cdot \pi(\theta_0) ds} = \left| \begin{array}{l} u = s\sqrt{\mathbb{I}(\theta_0)} \\ ds = \frac{du}{\sqrt{\mathbb{I}(\theta_0)}} \end{array} \right| = \\ &= \frac{\sqrt{\mathbb{I}(\theta_0)}}{\sqrt{2\pi}} e^{-\frac{t^2}{2} \mathbb{I}(\theta_0)} \sim \mathcal{N}\left(0, \frac{1}{\mathbb{I}(\theta_0)}\right). \end{aligned}$$

□

**Věta 6.9.** Mějme  $\dot{UBM}$ ,  $f_X$ ,  $\pi(\theta) > 0$  omezenou a vlastní. Označme  $\pi(\theta|\mathbf{x}) = \frac{f \cdot \pi}{\int f \cdot \pi d\theta}$ ,  $\pi_0(\theta|\mathbf{x}) = \frac{f \cdot 1}{\int f \cdot 1 d\theta}$ , kde  $\int f \cdot \pi d\theta < +\infty$  a  $\int f \cdot 1 d\theta < +\infty$ . Pak

$$\|\pi(\theta|\mathbf{x}) - \pi_0(\theta|\mathbf{x})\|_{TV} \leq \max\left(\frac{a+b}{1-a}, \frac{a+b+ac}{1+a+b+ac}\right) + \frac{a(2-a+c)}{1-a} = \varepsilon_{a,b,c},$$

kde  $a \in [0, 1)$ ,  $b > 0$ ,  $c > 0$ , jsou definovány následovně:

- 1)  $\exists A \subset \Theta$  tak, že  $\int_A \pi_0(\theta|\mathbf{x}) d\theta \geq 1 - a$ ,
- 2)  $\inf_A \pi(\theta) = m > 0$ ,
- 3)  $\sup_A \pi(\theta) \leq (1 + b)m$ ,

---

\*  $\frac{\partial \log f_n}{\partial \theta} \Big|_{\theta=\hat{\theta}_n} = 0$ , protože  $\hat{\theta}_n$  je řešením soustavy věrohodnostních rovnic

† Záměna limity a integrálu: z MIPu známe větu, která říká, že v případě hustot a integrací dle pravděpodobnostní míry nepotřebujeme Lebesgueovskou majorantu.

## 6 Asymptotické vlastnosti aposteriorní hustoty a Bayesovských bodových odhadů

$$4) \sup_{\Theta \setminus A} \pi(\theta) \leq (1 + c)m.$$

*Důkaz.* Bez důkazu. □

**Důsledek 6.10.** *Pokud dokážeme stlačit horní hranici  $\varepsilon_{a,b,c}$  k nule, tak v TV jsou  $\pi(\theta|\mathbf{x})$  a  $\pi_0(\theta|\mathbf{x})$  velmi blízko. Potom tedy  $\hat{\theta}_B^\pi = \mathbb{E}[\pi(\theta|\mathbf{x})]$  a  $\hat{\theta}_B^1 = \mathbb{E}[\pi_0(\theta|\mathbf{x})]$  jsou blízko. To znamená, že vliv  $\pi(\theta)$  se ztrácí.*

POZNÁMKA 6.11.  $\varepsilon_{a,b,c}$  chceme malé. Potřebujeme  $a, b$  malé,  $c$  ne příliš velké.

## 7 Princip neurčitosti

Problém principu neurčitosti spočívá v tom, že máme možnost volit nevlastní apriorní hustotu ve tvaru  $\pi(\theta) = c$  na  $\Theta$ , což znamená, že původně o parametru  $\theta$  vůbec nic nevíme. Z fyzikální podstaty můžeme třeba vědět jen to, že se parametr nachází na  $\mathbb{R}^+$ . Uvedme příklad tohoto problému.


**PŘÍKLAD 7.1.** Mějme ÚBM,  $X \sim f(x|\theta)$ ,  $\theta \in (0, 1)$ ,  $\pi(\theta) = 1$  na  $(0, 1)$ . Podle Bayese získáme aposteriorní hustotu  $\pi(\theta|\mathbf{x})$  a z ní můžeme provést odhad  $\hat{\theta}_B(\mathbf{x})$ . Představme si nyní, že budeme chtít místo parametru odhadnout např. odmocninu z tohoto parametru. Označme tedy  $\eta = \theta^2$ ,  $\theta = \sqrt{\eta}$ . Po dosazení do původní hustoty získáme reparametrizaci

$$f(x | \theta = \sqrt{\eta}) = f(x|\eta).$$

$\theta$  považujeme za znáhodněné (apriorně předpokládáme, že o  $\theta$  nic nevíme). Transformace hustoty,  $\theta$  na  $\eta$  probíhá jako

$$\pi_H(\eta) = \pi(\underbrace{\sqrt{\eta}}_{\theta}) \cdot |\mathbb{J}_H(\eta)| = 1 \cdot \frac{1}{2\sqrt{\eta}} = \frac{1}{2\sqrt{\eta}},$$

kde  $\pi_H$  značíme obecně transformovanou informaci. Je paradoxní, že o  $\theta$  nemáme konkrétní apriorní informaci a přitom o  $\eta = \theta^2$  víme, že je nevlastní (viz obr. 7.1).



Obrázek 7.1: Znázornění transformace  $\pi(\theta)$ . O  $\theta$  nemáme konkrétní apriorní informaci, ale o  $\eta = \theta^2$  víme, že je nevlastní (není ani integrovatelná na 1). To ukazuje problém principu neurčitosti.

### 7.1 Jeffreysova hustota

Mějme  $X \sim f(x|\theta)$ ,  $\theta \in \Theta$ ,  $\theta \sim \pi(\theta)$ ,  $\mathcal{F} = \{f(x|\theta)\}$ . Zavedeme reparametrizaci  $\eta = H^{-1}(\theta)$ , tzn.  $\theta = H(\eta)$ .

$$f_H(x|\eta) = f(x|\theta = H(\eta)) = f(x|H(\eta)), \quad \text{takto získáme } \mathcal{F}_H.$$

Z  $\pi(\theta)$  vytvoříme  $\pi_H(\eta) = \pi(H(\eta)) \cdot |\mathbb{J}_H(\eta)|$ , kde  $\mathbb{J}_H(\eta)$  je Jacobián. Z ÚBM  $\{\mathcal{F}, \pi\}$  potom plyne aposteriorní hustota  $\pi(\theta|\mathbf{x}) \rightarrow \hat{\theta}_B(\mathbf{x}) = \mathbb{E}[\pi(\theta|\mathbf{x})]$ . Dále z ÚBM  $\{\mathcal{F}, \pi\}$  plyne ÚBM  $\{\mathcal{F}_H, \pi_H\}$  a z něho aposteriorní hustota  $\pi(\eta|\mathbf{x})$  a následně  $\hat{\eta}_B(\mathbf{x}) = \mathbb{E}[\pi(\eta|\mathbf{x})]$ . Pozor na  $\hat{\theta}_B \neq H(\hat{\eta}_B)$ ! To může být problém.

## 7 Princip neurčitosti

**Věta 7.2** (Jeffreys). Máme ÚBM  $\mathcal{F}, \pi(\theta)$ ,  $\eta = H^{-1}(\theta)$ ,  $\theta = H(\eta)$  a předpokládejme, že  $\theta \in \Theta \subset \mathbb{R}^k$  a že  $H$  je regulární transformace. Nechť  $\mathcal{F}$  je regulární systém hustot ( $\mathcal{F}_{reg}^+$ ). Po reparametrizaci máme  $\mathcal{F}_H$  a  $\pi_H$ . Volme  $\pi(\theta) = \sqrt{\det \mathbb{I}(\theta)}$ , kde  $\mathbb{I}(\theta)$  je Fishera informační matice pro  $\theta$  v  $\mathcal{F}$ . Pak  $\pi_H(\eta) = \sqrt{\det \mathbb{I}_H(\eta)}$  v  $\mathcal{F}_H$  a platí, že

$$\int_B \pi(\theta|\mathbf{x})d\theta = \int_{H^{-1}(B)} \pi_H(\eta|\mathbf{x})d\eta, \quad \forall B \in \mathcal{B}_\Theta \text{ (} B \text{ je borelovská množina)}.$$

*Důkaz.* Pro  $k = 1$ : (zbytek ponechán čtenáři ;) ) Nejprve tedy spočítáme

$$\begin{aligned} \int_B \pi(\theta|\mathbf{x})d\theta &= \frac{1}{c} \int_B f(\mathbf{x}|\theta)\pi(\theta)d\theta = \left| \begin{array}{c} \theta = H(\eta) \\ \mathbb{J}_H(\eta) \end{array} \right| = \frac{1}{c} \int_{H^{-1}(B)} \underbrace{f(\mathbf{x}|H(\eta))}_{f_H(\mathbf{x}|\eta)} \underbrace{\pi(H(\eta)) \cdot |\mathbb{J}_H(\eta)|}_{\pi_H(\eta)} d\eta = \\ &= \frac{1}{c} \int_{H^{-1}(B)} f_H(\mathbf{x}|\eta)\pi_H(\eta)d\eta = \int_{H^{-1}(B)} \pi_H(\eta|\mathbf{x})d\eta, \end{aligned}$$

neboť  $c$  je v obou případech stejné. Protože platí, že

$$\mathbb{I}_H(\eta) = \mathbb{E} \left[ \frac{\partial \log f_H(\eta)}{\partial \eta} \right]^2 = \mathbb{E} \left[ \frac{\partial \log f(X|H(\eta))}{\partial \theta} \frac{\partial H(\eta)}{\partial \eta} \right]^2 = \mathbb{I}(H(\eta)) \cdot \mathbb{J}_H^2(\eta),$$

pak

$$\begin{aligned} \pi_H(\eta) &= \pi(H(\eta)) \cdot |\mathbb{J}_H(\eta)| = \sqrt{\det \mathbb{I}(H(\eta))} \cdot |\mathbb{J}_H(\eta)| = \sqrt{\det \mathbb{I}_H(\eta) \mathbb{J}_H^{-2}(\eta)} \cdot |\mathbb{J}_H(\eta)| = \\ &= \sqrt{\det \mathbb{I}_H(\eta)}. \end{aligned}$$

Získali jsme tedy  $\pi(\theta) = \sqrt{\det \mathbb{I}(\theta)}$ , což je **Jeffreysova apriorní hustota** (nebo také Jeffreysův princip neurčitosti).  $\square$

Tedy pokud obecně o parametru  $\theta$  nevíme nic, tak máme 2 možnosti. Můžeme na celém oboru zvolit  $\pi(\theta) = 1$ , ale nebudeme mít zaručenou invarianci na reparametrizaci. Druhou možností je právě zvolit Jeffreysovu apriorní hustotu, která často není vlastní, ale můžeme pak použít Jeffreysovu větu. Pojdme si to ukázat na nějakém příkladu.

**PŘÍKLAD 7.3.** Mějme  $X \sim f_X(x|\lambda) = \text{Po}(\lambda)$ , tzn.  $f_{X_j} = \frac{\lambda^{x_j}}{x_j!} e^{-\lambda}$ ,  $f_{\mathbf{X}}(\mathbf{x}|\lambda) = \frac{\lambda^{\sum x_j}}{\prod x_j!} e^{-n\lambda}$ ,  $\lambda > 0$ .

a) Pokud je  $\lambda$  neznámé, pak  $\pi(\lambda) = 1$  na  $\mathbb{R}^+$  (nevlastní). (Je jedno, jestli vezmeme rovno 1 nebo nějaké jiné konstantě.)

$$\pi(\lambda|\mathbf{x}) = \frac{\int_0^{+\infty} f_{\mathbf{X}} \pi d\lambda}{\int_0^{+\infty} f_{\mathbf{X}} \pi d\lambda} = \frac{1}{c} \frac{1}{\prod x_j!} \lambda^{\sum_{j=1}^n x_j} e^{-n\lambda} \sim \text{Gamma} \left( \sum_{j=1}^n x_j + 1, n \right).$$

Pro připomenutí:  $\frac{1}{c} x^{\alpha-1} e^{-\beta x} = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x} \sim \text{Gamma}(\alpha, \beta)$

Bayesovský odhad pak bude ve tvaru

$$\hat{\lambda}_B = \mathbb{E} \left[ \text{Gamma} \left( \underbrace{\sum x_j + 1}_\alpha, \underbrace{n}_\beta \right) \right] = \frac{\alpha}{\beta} = \frac{1}{n} \sum_{j=1}^n x_j + \frac{1}{n} = \overline{X}_n + \frac{1}{n} \sim \overline{X}_n \text{ (MLE pro velká } n \text{)}.$$

b) Jeffreys: Zkonstruujeme apriorní informaci jako

$$\pi(\lambda) = \sqrt{\det \mathbb{I}(\lambda)} = \sqrt{\det \mathbb{E} \left[ -\frac{\partial^2 \log f_{\mathbf{X}}}{\partial \lambda^2} \right]} = \sqrt{n \cdot \frac{1}{\lambda}} = \sqrt{n} \frac{1}{\sqrt{\lambda}}.$$

## 7 Princip neurčitosti

Volíme  $\pi(\lambda) = \frac{1}{\sqrt{\lambda}}$ . V apriorní informaci nehraje konstanta roli, protože se vždy v Bayesově vzorci pokrátí, tedy můžeme vypustit  $\sqrt{n}$ .

$$\pi(\lambda|\mathbf{x}) = \frac{f(\mathbf{x}|\lambda)\pi(\lambda)}{\underbrace{\int_{<+\infty} f(\mathbf{x}|\lambda)\pi(\lambda)d\lambda}_{<+\infty}} = \frac{1}{c'} \lambda^{\sum_{j=1}^n x_j - \frac{1}{2}} e^{-n\lambda} \sim \text{Gamma}\left(\underbrace{\sum_{j=1}^n x_j + \frac{1}{2}}_{\tilde{\alpha}}, \underbrace{\frac{n}{2}}_{\tilde{\beta}}\right).$$

Bayesovský odhad  $\hat{\lambda}_B^J = \mathbb{E}\left[\text{Gamma}(\tilde{\alpha}, \tilde{\beta})\right] = \frac{\tilde{\alpha}}{\tilde{\beta}} = \overline{X}_n + \frac{1}{2n} \sim \overline{X}_n$  (MLE pro velká  $n$ ).  
Pro malá  $n$  se odhady v a) a b) liší.



## 8 Konjugované systémy apriorních hustot, princip maximální entropie

### 8.1 Limitní aposteriorní hustoty ( $\hat{\theta}_B$ )

**Definice 8.1.** Mějme ÚBM  $\{\mathcal{F}, \pi(\theta)\}$  a předpokládejme, že  $\pi \in \mathcal{H} := \{\pi(\theta, \lambda) : \lambda \in \Lambda\}$ . Volme  $\lambda_0 \in \partial\Lambda$  z hranice a definujme **limitní apriorní hustotu**  $\pi_{\lambda_0}(\theta) = \lim_{\substack{\lambda \rightarrow \lambda_0 \\ \lambda \in \Lambda}} c \cdot \pi(\theta, \lambda)$ ,

která bývá často nevlastní, a proto tak píšeme i konstantu  $c$ , která umožňuje vyhodit nějaké konstanty z původní hustoty, které by se případně nezlímtovaly na vlastní hodnotu.

**Definice 8.2.** Dále pak definujeme **limitní aposteriorní hustotu** (za předpokladu záměny integrálu a limity v parametrickém integrálu)

$$\pi_{\lambda_0}(\theta|\mathbf{x}) \stackrel{\text{ozn}}{=} \frac{f \pi_{\lambda_0}(\theta)}{\int_{\Theta} f \pi_{\lambda_0}(\theta) d\theta} = \frac{f \lim_{\lambda \rightarrow \lambda_0} c \pi(\theta, \lambda)}{\int_{\Theta} f \lim_{\lambda \rightarrow \lambda_0} c \pi(\theta, \lambda) d\theta} = \lim_{\substack{\lambda \rightarrow \lambda_0 \in \partial\Lambda \\ \lambda \in \Lambda}} \frac{f \pi(\theta, \lambda)}{\int f \pi(\theta, \lambda) d\theta} = \lim_{\lambda \rightarrow \lambda_0} \pi(\theta, \lambda|\mathbf{x}).$$

Z toho vyplývá, že  $\hat{\theta}_B^{\text{lim}} = \mathbb{E}[\pi_{\lambda_0}(\theta|\mathbf{x})]$ , což často vede na nějakou klasickou statistickou proceduru.

**PŘÍKLAD 8.3.** Mějme  $X \sim f_X(x|\theta) = \theta e^{-\theta x} = \text{Exp}(\theta)$ ,  $\theta > 0$ . Mějme

$$\mathcal{H} = \{\theta \sim \text{Gamma}(\alpha, \beta), \text{ tzn. } \pi(\theta, \underbrace{(\alpha, \beta)}_{\lambda}) = \theta^{\alpha-1} e^{-\beta\theta}\}, \quad \Lambda = \mathbb{R}^{2+}.$$

Víme, že  $\lambda_0 = (0, 0) \in \partial\Lambda$ , a proto  $\pi_{0,0}(\theta) = \lim_{(\alpha, \beta) \rightarrow (0,0)^+} \theta^{\alpha-1} e^{-\beta\theta} = \frac{1}{\theta}$  (nevlastní).

$$\pi_{(0,0)}(\theta|\mathbf{x}) = \frac{f_X(x|\theta) \cdot \frac{1}{\theta}}{\underbrace{\int_0^{+\infty} f_X(x|\theta) \cdot \frac{1}{\theta} d\theta}_{<+\infty}} \stackrel{iid}{=} \frac{\theta^n e^{-\theta \sum_{j=1}^n x_j} \cdot \frac{1}{\theta}}{c} = \frac{1}{c} \theta^{n-1} e^{-\theta \sum_{j=1}^n x_j} \sim \text{Gamma}\left(n, \sum_{j=1}^n x_j\right),$$

$$\hat{\theta}_B^{\text{lim}} = \mathbb{E}\left[\text{Gamma}\left(n, \sum_{j=1}^n x_j\right)\right] = \frac{n}{\sum_{j=1}^n x_j} = (\overline{X_n})^{-1} = \hat{\theta}_{\text{ML}}.$$

Pokud bychom chtěli dostat pouze  $\overline{X_n}$ , tak bychom v  $\mathcal{H}$  museli namísto Gamma rozdělení použít inverzní Gamma rozdělení.

**PŘÍKLAD 8.4.** Volba  $\pi(\theta)$  je subjektivní. Příkladem je studie New England Journal of Medicine. Zkoumali, kolik lidí by bylo ochotných jít na operaci kvůli rakovině plic, ale pacienty rozdělili na dvě skupiny, přičemž každé podali informaci o přežití jiným způsobem.

První skupině řekli, že šance na přežití je 68%. V takovém případě by šlo na operaci 44% lidí. Druhé skupině bylo sděleno, že pravděpodobnost úmrtí je 32%. V tom případě by šlo na operaci jen 18% lidí.

V obou případech tak byla pacientům sdělena stejná apriorní informace, ale v obou případech se počet lidí, kteří by šli na operaci, lišil. Vyhodnocení apriorní informace je tedy hodně subjektivní, můžeme získat jiné odhady na základě stejných dat.

**Empirical Bayes**

Máme  $\mathcal{H} = \{\pi(\theta, \lambda) : \lambda \in \Lambda\}$ . Spočítá se marginální rozdělení  $m_\lambda(\mathbf{x}) = \int_{\Theta} \underbrace{f(\mathbf{x}|\theta)\pi(\theta, \lambda)}_{\varphi(\mathbf{x}, \theta, \lambda)} d\theta$ .

Vezmeme data  $\mathbf{x}$  a na základě dat odhadneme klasickou statistickou procedurou (např. pomocí MLE) parametr  $\hat{\lambda}(\mathbf{x})$  v  $m_\lambda(\mathbf{x})$  a provedeme Bayesovský princip s apriorní hustotou  $\pi(\theta, \hat{\lambda}_{\text{ML}})$  klasickou statistickou procedurou  $\hat{\lambda}_{\text{ML}}$ .

Druhou možností volby je použít princip maximální entropie ve tvaru  $H(\pi) = - \int_{\Theta} \pi(\theta) \log \pi(\theta) d\theta$ . Parametr  $\pi$  potom volíme tak, aby  $H(\pi)$  bylo maximální.

Pokud máme omezení ve formě  $\mathbb{E}^\pi[g_i(\theta)] = \omega_i, \forall i \in K$  (což je počet vazeb), pak maximální  $H(\pi)$  dostaneme za použití

$$\pi^*(\theta_i) = \frac{e^{\sum_{j=1}^n \lambda_j g_j(\theta_i)}}{\sum_i e^{\sum_{j=1}^n \lambda_j g_j(\theta_i)}}, \quad \forall i,$$

kde  $\lambda_j$  jsou Lagrangeovy multiplikátory.

Pro spojitý model musíme zavést tzv. *Kulback-Leiblerovu vzdálenost* vztahem

$$\text{KL}(\pi, \pi_0) = \mathbb{E}^\pi \left[ \log \frac{\pi_0}{\pi} \right] = \int \pi \log \frac{\pi_0}{\pi} d\theta.$$

Pokud  $\pi_0 = 1$ , pak  $\text{KL}(\pi, 1) = - \int \pi \log \pi = H(\pi)$ . Naše volba  $\pi$  tedy závisí na  $\pi_0$  (za nejméně informativní rozdělení), což je opět velice subjektivní volba.

**8.2 Konjugované rodiny**

**Definice 8.5** (Konjugované systémy apriorních hustot). Mějme systém hustot  $\mathcal{F} = \{f(\mathbf{x}|\theta) : \theta \in \Theta \subset \mathbb{R}^k\}$  a označme  $\mathcal{H}$  systém apriorních hustot pro  $\theta$ . Pak  $\mathcal{H}$  nazveme **konjugovaný systém apriorních hustot** (*Conjugated Family* = **CF**) pro  $\mathcal{F}$ , pokud  $\pi(\theta|\mathbf{x}) \in \mathcal{H}$ .

**Věta 8.6.** Mějme  $\mathcal{F}_n = \{f_{\mathbf{X}}(\mathbf{x}|\theta) = \prod_{j=1}^n f_{X_j}(x_j|\theta)\}$  id a předpokládejme, že  $T_n(\mathbf{X})$  je postačující statistika pro  $\mathcal{F}_{\mathbf{X}}$ , tzn. dle Neymannova faktorizačního kritéria

$$f_{\mathbf{X}}(\mathbf{y}|\theta) = h_n(\mathbf{y})g_n(\theta, T_n(\mathbf{y})), \quad \forall \theta, \forall \mathbf{y}, \forall n.$$

Pak platí, že

$$\mathcal{H} = \left\{ \frac{g_m(\boldsymbol{\theta}, \mathbf{t})}{\int_{\Theta} g_m(\boldsymbol{\theta}, \mathbf{t}) d\boldsymbol{\theta}} : \forall m \in \mathbb{N}, \forall \mathbf{t} \in S_m, \text{ kde } S_m = \{\mathbf{t} : \exists \mathbf{y}, \text{ že } T_m(\mathbf{y}) = \mathbf{t}\} \right\}$$

je konjugovaný systém apriorních hustot.

*Důkaz.* Volíme apriorní hustotu  $\pi(\theta) \in \mathcal{H}$ , tzn.  $\pi(\theta) \sim g_m(\theta, \mathbf{t})$ . Z toho vyplývá, že  $\exists \mathbf{y}$  tak, že  $T_m(\mathbf{y}) = \mathbf{t}$ . Dále platí, že

$$\begin{aligned} \pi(\theta | \underbrace{\mathbf{x}}_{\dim n}) &\sim f_n(\mathbf{x}|\theta) \cdot g_m(\theta, \mathbf{t}) \sim \underbrace{g_m(\theta, T_m(\mathbf{y})) \cdot h_m(\mathbf{y})}_{\text{NFK} \Rightarrow f_m(\mathbf{y}|\theta)} \cdot f_n(\mathbf{x}|\theta) = f_m(\mathbf{y}|\theta) \cdot f_n(\mathbf{x}|\theta) = \\ &= \prod_{j=1}^m f(y_j|\theta) \prod_{j=1}^n f(x_j|\theta) = \prod_{j=1}^{m+n} \underbrace{f_{Z_j}(z_j|\theta)}_{\mathbf{z}=(\mathbf{y}, \mathbf{x})} = f_{m+n}(\mathbf{z}|\theta) \stackrel{\text{NFK}}{=} \underbrace{h_{n+m}(\mathbf{z})}_{\text{konst}} \cdot g_{n+m}(\theta, \underbrace{T_{n+m}(\mathbf{y})}_{\mathbf{t} \in S_{n+m}}) \sim g_{n+m}(\theta, \mathbf{t}) \end{aligned}$$

Z tohoto důkazu jsme dostali přirozenou CF. Vhodným rozšířením na  $m \in \mathbb{R}$  vznikne obvyklá CF. □

## 8 Konjugované systémy apriorních hustot, princip maximální entropie

PŘÍKLAD 8.7. Mějme  $X \sim f_X(x|\theta) = \lambda e^{-\lambda x} = \text{Exp}(\lambda)$ ,  $\lambda > 0$ . Potom

$$\mathcal{F}_n : f_n(\mathbf{x} | \underbrace{\theta}_{\lambda}) = \lambda^n e^{-\lambda \sum_{j=1}^n x_j} = \left| \begin{array}{l} \text{ozn. } T_n(\mathbf{x}) = \sum_{j=1}^n x_j \\ \text{je PS pro } \mathcal{F}_n \end{array} \right| = 1 \cdot g_n(\lambda, T_n(\mathbf{x})).$$

Označme  $\sum_{j=1}^n x_j = t$ . Potom

$$\mathcal{H} = \left\{ \frac{g_m(\lambda, t)}{c} : m \in \mathbb{N}, t \in S_m, \dots \right\} = \left\{ \underbrace{\lambda^m \frac{e^{-\lambda t}}{c}}_{\text{Gamma}(m+1, t)} : m \in \mathbb{N}, t \in S_m = \{\mathbf{t} = \sum_{j=1}^m x_j\} = \mathbb{R}^+ \right\},$$

čímž jsme získali přirozenou CF. To lze opět rozšířit na obvyklou CF:  $\text{Gamma}(\alpha, \beta) = \mathcal{H}_{\text{obv}}$ ,  $\alpha, \beta > 0$  (rozšíření v  $\alpha, \mathbb{N} \rightarrow \mathbb{R}^+$ ).

Jelikož  $X \sim \text{Exp}(\lambda)$ ,  $\pi(\lambda) = \text{Gamma}(\alpha, \beta)$ , pak

$$\pi(\lambda|\mathbf{x}) = \frac{\lambda^n e^{-\lambda \sum_{j=1}^n x_j} \frac{1}{c} \lambda^{\alpha-1} e^{-\lambda \beta}}{\int_0^{+\infty} \lambda^n e^{-\lambda \sum_{j=1}^n x_j} \frac{1}{c} \lambda^{\alpha-1} e^{-\lambda \beta} d\lambda} = \frac{\lambda^{n+\alpha-1} e^{-\lambda(\sum_{j=1}^n x_j + \beta)}}{c} \sim \text{Gamma}(n+\alpha, \sum_{j=1}^n x_j + \beta) \in \mathcal{H}_{\text{obv}}.$$

PŘÍKLAD 8.8 (Příklady CF). a)  $X \sim \text{Bi}(n, p) \Rightarrow CF \mathcal{H} = \{\pi(p) \sim \text{Beta}(\alpha, \beta)\}$ ,

b)  $X \sim \text{Poisson}(\lambda) \Rightarrow CF \mathcal{H} = \{\pi(\lambda) \sim \text{Gamma}(\alpha, \beta)\}$ ,

c)  $X \sim U(0, \theta)$ ,  $\theta \in \mathbb{R}^+ \Rightarrow CF \mathcal{H} = \{\pi(\theta) \sim \text{Pareto}(a, b)\}$ , kde Paretovo rozdělení je mocninného typu  $\theta \sim \frac{a}{b} \left(\frac{b}{\theta}\right)^{a+1}$ ,  $\theta \geq b$ , které má těžké chvosty.

d) 1)  $X \sim \mathcal{N}(\mu, \sigma_0^2)$  a známe  $\sigma_0 > 0$ . Pak postačující statistika je ve tvaru  $T_n(\mathbf{X}) = \sum_{j=1}^n X_j \in \mathbb{R}$ . Potom

$$\mathcal{H}_{\text{CF}_{\text{obv}}} = \{\pi(\mu) \sim \mathcal{N}(a, b^2), a \in \mathbb{R}, b > 0\}$$

a pomocí parametrů  $a, b$  ladíme tvar apriorní informace.

2)  $X \sim \mathcal{N}(\mu_0, \sigma^2)$  a známe  $\mu_0$ . Pak postačující statistika je ve tvaru  $T_n(\mathbf{X}) = \sum_{j=1}^n (X_j - \mu_0)^2$ , protože

$$f_{\mathbf{X}} = \underbrace{\frac{1}{c} e^{-\frac{1}{2\sigma^2} \sum_{j=1}^n (X_j - \mu_0)^2}}_{g_n(t, \sigma^2)},$$

a proto  $\mathcal{H}_{\text{obv}}$  pro parametr  $\underbrace{\frac{1}{\sigma^2}}_{\theta} = \{\pi(\theta) \sim \text{Gamma}(\alpha, \beta)\}$ .

3)  $X \sim \mathcal{N}(\mu, \sigma^2)$  a neznáme nic. Potom  $T_n(\mathbf{X}) = \left( \sum_{j=1}^n X_j, \sum_{j=1}^n X_j^2 \right) \in \mathbb{R} \times \mathbb{R}_0^+$  je postačující statistika, a proto  $\mathcal{H}_{\text{obv}}$  pro  $(\mu, \frac{1}{\sigma^2})$  definujeme tak, že  $\pi(\mu | \frac{1}{\sigma^2}) \sim \mathcal{N}$  a  $\pi(\frac{1}{\sigma^2}) \sim \text{Gamma}$ . Z toho pak

$$\left\{ \pi\left(\mu, \frac{1}{\sigma^2}\right) = \pi\left(\mu \middle| \frac{1}{\sigma^2}\right) \pi\left(\frac{1}{\sigma^2}\right) = \underbrace{\mathcal{N} \cdot \text{Gamma}}_{\text{normální-gamma rozdělení}} \right\}.$$

POZNÁMKA 8.9 (Směs z CF). Pokud CF nevyhovuje naší představě, můžeme zkusit vybrat směs (váženou kombinaci) jako  $\pi(\theta) = \sum_{i=1}^l w_i \pi_i(\theta)$ , kde  $\pi_i \in \mathcal{H}_{\text{CF}}$  a  $w_i > 0$  jsou váhy splňující podmínku  $\sum_{i=1}^l w_i = 1$ . Pak můžeme vyjádřit aposteriorní hustotu jako

$$\pi(\theta|\mathbf{x}) = \frac{f\pi}{\int f\pi} = \frac{1}{c} \sum_{i=1}^l w_i f \pi_i(\theta) = \frac{1}{c} \sum_{i=1}^l w_i c_i \frac{f \pi_i}{c_i} = \sum_{i=1}^l \underbrace{\frac{w_i c_i}{c}}_{w'_i} \pi_i(\theta|\mathbf{x}) = \sum_{i=1}^l w'_i \underbrace{\pi_i(\theta|\mathbf{x})}_{\mathcal{H}_{\text{CF}}},$$

kde  $c_i = \int f \pi_i d\theta$ . Můžeme tedy spojit několik rozdělení do jednoho složitějšího a získat tím daleko hodnotnější informaci.

## 9 Nejméně příznivá apriorní rozdělení

### 9.1 Propojování Bayesovské statistiky s klasickou statistikou (nejméně příznivé rozdělení)

V předchozích kapitolách jsme měli **parametrický prostor**  $\theta \in \Theta$ , případně  $\tau(\theta) \in \mathcal{T}$ , dále **rozhodovací prostor**  $\mathcal{D}' \ni d$ , **ztrátovou funkci**  $L(\theta, d)$ , kterou se snažila minimalizovat rozhodovací funkce  $\delta_L$ ,  $\forall \theta, \forall \mathbf{x}$ . Měli jsme také rizikovou funkci  $\mathcal{R}(\theta, \delta) = \mathbb{E}^f L(\theta, \delta(\mathbf{X}))$  a rozhodovací funkci  $\delta_U$ ,  $\forall \theta$ , která ji minimalizovala. Dále pak **supremální rizikovou funkci**  $\sup_{\theta} \mathcal{R}(\theta, \delta)$  a rozhodovací funkci  $\delta_0$ , která ho minimalizovala.

Definovali jsme dále **apriorní Bayesovské riziko** vztahem  $r(\pi, \delta) = \mathbb{E}^{\pi} \mathcal{R}(\theta, \delta)$ , které se snažilo minimalizovat  $\delta^{\pi} = \underset{\delta \in \mathcal{D}}{\operatorname{argmin}} r(\pi, \delta)$ .

**Definice 9.1.** Definujeme **maximinální riziko** vztahem

$$\underline{\mathcal{R}} = \sup_{\pi \in \Pi} r(\pi, \delta^{\pi}) = \sup_{\pi \in \Pi} \inf_{\delta} r(\pi, \delta) = \sup_{\pi \in \Pi} r(\pi),$$

kde  $\Pi$  je rodina apriorních hustot.

**Věta 9.2.**  $\underline{\mathcal{R}} \leq \overline{\mathcal{R}}$ , kde  $\overline{\mathcal{R}} = \inf_{\delta} \sup_{\theta} \mathcal{R}(\theta, \delta)$  je *minimaxní riziko*.

*Důkaz.* Volme apriorní rozdělení  $\pi(\theta)$ . Potom

$$r(\pi, \delta) = \int_{\Theta} \underbrace{\mathcal{R}(\theta, \delta)}_{\geq 0 \wedge \leq \sup_{\theta} \mathcal{R}(\theta, \delta)} \underbrace{\pi(\theta)}_{\geq 0} d\theta \leq \int_{\Theta} \sup_{\theta} \mathcal{R}(\theta, \delta) \pi(\theta) d\theta = \sup_{\theta} \mathcal{R}(\theta, \delta) \cdot \underbrace{\int_{\Theta} \pi(\theta) d\theta}_1.$$

Dále platí nerovnice

$$\begin{aligned} r(\pi, \delta) &\leq \sup_{\theta} \mathcal{R}(\theta, \delta), \quad \forall \delta, \forall \pi \\ \inf_{\delta} r(\pi, \delta) &\leq \inf_{\delta} \sup_{\theta} \mathcal{R}(\theta, \delta) = \overline{\mathcal{R}}, \quad \forall \pi \\ \sup_{\pi} \inf_{\delta} r &= \underline{\mathcal{R}} \leq \sup_{\pi} \overline{\mathcal{R}} = \overline{\mathcal{R}} \end{aligned}$$

□

**POZNÁMKA 9.3.** Pokud  $\delta^{\pi}$  dosahuje na  $\underline{\mathcal{R}}$  a  $\underline{\mathcal{R}} = \overline{\mathcal{R}}$  ve větě 9.2, pak  $\delta^{\pi}$  je současně **minimaxní strategie**.

**Definice 9.4.** Pokud existuje  $\pi^*(\theta)$  apriorní rozdělení takové, že  $r(\pi^*) = \underline{\mathcal{R}}$ , tzn.  $\forall \pi \in \Pi, r(\pi) \leq r(\pi^*)$ , pak se nazývá **nejméně příznivé** (*least favourable* = **LF**).

**Věta 9.5.** *Nechť  $\pi$  je vlastní apriorní rozdělení na  $\Theta$  takové, že  $r(\pi) = \sup_{\theta} \mathcal{R}(\theta, \delta^{\pi})$ . Pak*

1.  $\delta^{\pi}$  je *minimaxní strategií*,
2. *pokud  $\delta^{\pi}$  jednoznačné Bayesovské řešení, pak  $\delta^{\pi}$  je jednoznačná minimaxní strategie,*

## 9 Nejmeně příznivá apriorní rozdělení

3.  $\pi$  je nejmeně příznivé rozdělení (LF).

*Důkaz.* 1. Vezmeme  $\delta$  libovolné fixní. Víme, že

$$\sup_{\theta} \mathcal{R}(\theta, \delta) \cdot 1 = \sup_{\theta} \mathcal{R}(\theta, \delta) \int \pi(\theta) d\theta \wedge \sup_{\theta} \mathcal{R}(\theta, \delta) \geq \mathcal{R}.$$

Potom

$$\sup_{\theta} \mathcal{R}(\theta, \delta) \geq \int \mathcal{R} \pi(\theta) d\theta = \mathbb{E}^{\pi} \mathcal{R} = r(\pi, \delta) \geq r(\pi, \delta^{\pi}) = r(\pi) = \sup_{\theta} \mathcal{R}(\theta, \delta^{\pi}).$$

2. Analogicky jako předchozí bod, akorát  $r(\pi, \delta) > r(\pi, \delta^{\pi})$

3. Volíme  $\pi'$  libovolné fixní. Pak  $r(\pi') = r(\pi', \delta^{\pi'}) \leq r(\pi', \delta^{\pi}) \leq \sup_{\theta} \mathcal{R}(\theta, \delta^{\pi}) = r(\pi)$ .

Potom  $\pi = \pi^*$  je LF.

□

**POZNÁMKA 9.6.** Věta 9.5 je jednou z prvních vět o tom, jak lze za daných podmínek z Bayesovské strategie získat klasickou minimaxní strategii.

**Důsledek 9.7.** Věta platí například tehdy, když  $\mathcal{R}(\theta, \delta^{\pi})$  je konstantní v  $\theta$  na  $\Theta$  s.j. vzhledem k apriornímu rozdělení  $\pi$ , protože pak platí, že  $r(\pi) = \sup \mathcal{R}$ .

**Definice 9.8.** Nejmeně příznivá posloupnost  $(\pi_n)_{n=1}^{+\infty}$  je taková, pro kterou existuje  $\lim_{n \rightarrow +\infty} r(\pi_n) = \mathcal{R}$ .

**Věta 9.9.** Nechť  $(\pi_n)_{n=1}^{+\infty}$  je posloupnost taková, že  $\lim_{n \rightarrow +\infty} r(\pi_n) = r$ . Nechť dále  $\delta_0$  je libovolná rozhodovací funkce taková, že  $\sup_{\theta} \mathcal{R}(\theta, \delta_0) = r$ . Pak v analogii s větou 9.5

1.  $\delta_0$  je minimaxní,
2. NELZE VYSLOVIT  $a$
3.  $(\pi_n)_{n=1}^{+\infty}$  je nejmeně příznivá posloupnost apriorních rozdělení (LF).

*Důkaz.* Analogicky jako ve větě 9.5 (tedy za domácí cvičení). □

**PŘÍKLAD 9.10.** Mějme  $X \sim \text{Bi}(n, p)$ , kde se snažíme nalézt parametr  $\hat{p}$ .  $\pi(p) \sim \text{Beta}(a, b) \sim \frac{1}{B(a, b)} p^{a-1} (1-p)^{b-1}$ , kde  $a, b > 0$ .

Příkladem může být teorie spolehlivosti, kde máme datové pole v RAIDu, tj.  $n$ -komponentní systém. Označme  $X$  počet poruch za čas 1. Pokud nastane jev  $\{X \geq 5\}$ , tak nastane výpadek. Tuto pravděpodobnost se snažíme najít, tedy  $\mathbb{P}(X \geq 5) = \hat{p}$ . Střední počet poruch pak můžeme odhadnout jako  $\widehat{\mathbb{E}X} = n\hat{p}$  za čas 1.

- 1) Můžeme například udělat apriorní odhad  $\hat{p}_a = \mathbb{E}[\text{Beta}(a, b)] = \frac{a}{a+b}$ .
- 2) Můžeme také naměřit data  $x$  a vypočítat klasický ML odhad jako  $\hat{p}_{\text{ML}} = \frac{x}{n} = \overline{x_n}$ . Pokud  $L = L_2$ , tak je to dokonce  $\hat{p}_{\text{UMVUE}}$ .
- 3) Můžeme také udělat Bayesovský odhad jako


$$\pi(p|x) = \frac{\binom{n}{x} p^x (1-p)^{n-x} \cdot \frac{1}{B(a, b)} p^{a-1} (1-p)^{b-1}}{c} = \frac{1}{c} p^{x+a-1} (1-p)^{n-x+b-1} \sim \text{Beta}(x+a, n-x+b).$$

Z toho potom  $\hat{p}_B = \mathbb{E}[\text{Beta}(x+a, n-x+b)] = \frac{x+a}{n+a+b} = \frac{\overline{x_n} + \frac{a}{n}}{1 + \frac{a+b}{n}}$ . Zároveň však lze  $\hat{p}_B$  zapsat jako konvexní kombinaci z bodu 2 ve tvaru

$$\hat{p}_B = \underbrace{\frac{a+b}{a+b+n}}_{\alpha_n} \frac{a}{a+b} + \underbrace{\frac{n}{n+a+b}}_{1-\alpha_n} \frac{x}{n} = \alpha_n \hat{p}_a + (1-\alpha_n) \hat{p}_{\text{ML}},$$

## 9 Nejméně příznivá apriorní rozdělení

kde  $\alpha_n$  se nazývá porce neurčitosti apriorní znalosti. Ukažme si nyní, co vlastně dělá to  $\hat{p}_a$ :



Obrázek 9.1: Rozdělení  $\pi(p) = \text{Beta}(\frac{\sqrt{n}}{2}, \frac{\sqrt{n}}{2})$  pro vybraná  $n$ .

- Pokud je  $n$  pevné,  $a, b$  velké a  $b/a = \text{konst.}$  Potom  $\alpha_n \rightarrow 1$ , a tedy  $\hat{p}_B = \hat{p}_a$ .
- Pokud jsou  $a, b$  pevné a  $n$  velké, pak  $\alpha_n \rightarrow 0$  ( $\alpha_n \doteq 0$ ), a tedy  $\hat{p}_B = \hat{p}_{\text{ML}}$ .
- Pokud  $a = b = 1$ , tedy  $\pi(p) = U(0, 1)$  podle principu neurčitosti. Potom  $\hat{p}_B = \frac{x+1}{n+2} \doteq \hat{p}_{\text{ML}}$  pro vysoká  $n$ .
- Pokud  $a = b = 0$ ,  $\pi(p) = p^{-1}(1-p)^{-1}$  je apriorní nevlastní limitní rozdělení, pak  $\hat{p}_B = \hat{p}_{\text{ML}}$ .
- Pokud  $a = a_n = \frac{\sqrt{n}}{2}$ ,  $b = b_n = \frac{\sqrt{n}}{2}$ , tedy  $\pi(p) = \text{Beta}(\frac{\sqrt{n}}{2}, \frac{\sqrt{n}}{2})$  (závisí na  $n$ ). Potom

$$\begin{aligned} \hat{p}_B = \frac{x + \frac{\sqrt{n}}{2}}{n + \sqrt{n}} &\Rightarrow \mathcal{R}(p, \hat{p}_B) \stackrel{L=L_2}{=} \mathbb{E}_{L_2(p, \hat{p}_B)} \underbrace{(p - \hat{p}_B)^2}_{L_2(p, \hat{p}_B)} = \mathbb{E} \left( p - \frac{X + \frac{\sqrt{n}}{2}}{n + \sqrt{n}} \right)^2 = \\ &= c \underbrace{\mathbb{E} X^2}_{np - np^2 + n^2 p^2} + c' \underbrace{\mathbb{E} X}_{np} + e \doteq \frac{n}{4(n + \sqrt{n})^2} = \text{konst.} \end{aligned}$$

To ilustruje obrázek 9.1. Dle věty 9.5 a důsledku 9.7 víme, že  $r(\pi) = \sup_{\theta} \mathcal{R}(\theta, \delta^\pi)$

implikuje to, že  $\hat{p}_B = \hat{p}_{\text{minimax}}$  a  $\pi^* = \pi(p)$  je LF.

**PŘÍKLAD 9.11.** Mějme  $X \sim \mathcal{N}(\mu, 1) = \mathcal{N}(\theta, 1)$  a zkoumáme  $\hat{\mu}$  na základě dat  $x$ . Můžeme tedy vzít  $\hat{\mu}_{\text{ML}} = \bar{x}_n$  (pokud naměříme více dat).

A) Zvolíme nevlastní neurčitou informaci  $\pi(\mu) = \text{konst} = 1$  na  $\mathbb{R}$  ( $\hat{\mu}_a$  není nevlastní).

$$\pi(\mu|x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(x-\mu)^2} \cdot \frac{1}{c} = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}(\mu-x)^2} \sim \mathcal{N}(x, 1).$$

$$\hat{\mu}_B = \mathbb{E}[\mathcal{N}(x, 1)] = \bar{x}_n,$$

$$\mathcal{R}(\mu, \hat{\mu}_B) \stackrel{L=L_2}{=} \mathbb{E}(\mu - X)^2 = \text{DX} = 1,$$

tzn.  $\mathcal{R}(\mu, \hat{\mu}_B) = \text{konst.}$  Nemůžeme ale aplikovat větu 9.5, protože  $\pi$  není vlastní.

B)  $\pi_n(\mu) = \mathcal{N}(0, n)$  je vlastní hustota  $\forall n$  (CF) a zkusíme použít větu 9.9. (Měli bychom vědět, že  $A \propto B$  značí, že existuje konstanta  $k$  taková, že  $A = kB$ .)

$$\pi_n(\mu|x) \propto e^{-\frac{1}{2}(x-\mu)^2} e^{-\frac{1}{2n}(\mu-0)^2} \propto e^{-\frac{1}{2} \left[ \left(1 + \frac{1}{n}\right) \mu^2 - 2\mu x + x^2 \right]} \propto e^{-\frac{1}{2} \left(1 + \frac{1}{n}\right) \left[ \mu - \frac{n}{n+1} x \right]^2} \sim \mathcal{N}\left(\frac{n}{n+1} x, \frac{n}{n+1}\right)$$

9 Nejméně příznivá apriorní rozdělení

$$\hat{\mu}_B = \mathbb{E}\mathcal{N}\left(\frac{n}{n+1}x, \frac{n}{n+1}\right) = \frac{n}{n+1}x = \delta^{\pi_n} \sim \hat{\mu}_{B,n}.$$

$$r(\pi_n) \stackrel{L=L_2}{=} \mathbb{D}\pi(\mu|x) = \frac{n}{n+1} \rightarrow 1 \text{ (vzorec ověříme v následující větě).}$$

$\lim_{n \rightarrow +\infty} r(\pi_n) = 1 = r$  a víme, že máme  $\delta_0$ , pro které je  $r = \mathcal{R}(\mu, \underbrace{\hat{\mu}_B}_{\substack{\text{z A)} \\ = \delta_0 = x}})$ . Potom dle věty

**9.9** je  $\delta_0 = x$  minimaxní a posloupnost  $\mathcal{N}(0, n)$  je LF.

**Věta 9.12** (!!!Vyhadzovací!!!). *Mějme ÚBM,  $X \sim f(x|\theta)$ ,  $\pi(\theta)$ ,  $L(\theta, d) = L_2(\theta, d) = (\theta - d)^2$ . Nechť pro aposteriorní střední hodnotu platí, že  $0 < \mathbb{E}^\pi(\theta^2|x) < +\infty$  ( $\neq 0$  aby nebyla degenerovaná). Pak*

$$\delta^\pi(x) = \mathbb{E}^\pi(\theta|x) = \int_{\Theta} \theta \pi(\theta|x) d\theta = \frac{\int \theta f(x|\theta) \pi(\theta) d\theta}{\int f(x|\theta) \pi(\theta) d\theta}$$

a Bayesovské riziko

$$r(\pi) = \mathbb{E}^m[\mathbb{D}^\pi(\theta|x)],$$

kde  $m(x) = \int f \pi d\theta$ .

*Důkaz.* Vyjdeme z definice Bayesovského odhadu  $\delta^\pi = \underset{\delta}{\operatorname{argmin}} r(\pi, \delta)$ .

$$\begin{aligned} r(\pi, \delta) &= \mathbb{E}^\pi[\mathcal{R}(\theta, \delta)] = \mathbb{E}^\pi[\mathbb{E}^f(\theta - \delta(X))^2] = \left| \begin{array}{c} \text{záměna} \\ \mathbb{E}^\pi \text{ a } \mathbb{E}^f \end{array} \right| \stackrel{\text{viz dříve}}{=} \mathbb{E}^m[\mathbb{E}^\pi(\theta - \delta(x))^2|x] = \\ &= \mathbb{E}^m[\mathbb{E}^\pi(\theta^2|x) - 2\delta(x)\mathbb{E}^\pi(\theta|x) + \delta(x)^2] = \underbrace{\mathbb{E}^m[\mathbb{E}^\pi(\theta^2|x)]}_{0 < \dots < +\infty} + \underbrace{(\delta(x) - \mathbb{E}^\pi(\theta|x))^2}_{0 < \dots < +\infty} - \underbrace{(\mathbb{E}^\pi(\theta|x))^2}_{0 < \dots < +\infty} \end{aligned}$$

Abychom tento výraz optimalizovali, musíme vzít  $\delta^\pi = \delta(x) = \mathbb{E}^\pi(\theta|x)$ , abychom výraz minimalizovali.


$$r(\pi) = r(\pi, \delta^\pi) = \mathbb{E}^m[\underbrace{\mathbb{E}^\pi(\theta - \mathbb{E}^\pi(\theta|x))^2}_{\mathbb{D}(\theta|x)}|x].$$

Záměna je provedena obdobně jako ve větě 5.12. □

# 10 Přípustnost Bayesovského řešení, Steinův efekt, Bergerův jev

## 10.1 Přípustnost (Admissibility)

**Definice 10.1.** Mějme  $\mathcal{D}', \Theta, \dots$  Rozhodovací funkce  $\delta_0$  se nazývá **nepřípustná**, pokud existuje  $\delta_1$ , která dominuje  $\delta_0$ , ozn.  $\delta_1 \ll \delta_0$ , tzn.  $\mathcal{R}(\theta, \delta_1) \leq \mathcal{R}(\theta, \delta_0)$ ,  $\forall \theta \in \Theta$  (stejněměrně) a  $\exists \theta_0 \in \Theta$  tak, že  $\mathcal{R}(\theta_0, \delta_1) < \mathcal{R}(\theta_0, \delta_0)$ . V případě, že taková  $\delta_1$  neexistuje, nazýváme  $\delta_0$  **přípustný**.



Obrázek 10.1: Vlevo jsou přípustné všechny 4 odhady, protože žádný z nich nejde stejnoměrně vylepšit nějakým jiným odhadem. Vpravo už je ale  $\mathcal{R}(\theta, \delta_0)$  nepřípustný, protože ho můžeme stejnoměrně vylepšit funkcí  $\mathcal{R}(\theta, \delta_4)$ .

**Věta 10.2.** •  $\delta_U = \operatorname{argmin}_{\delta} \mathcal{R}(\theta, \delta)$ ,  $\forall \theta$ , je vždy přípustný, pokud existuje,

- $\delta_0 = \operatorname{argmin}_{\delta} \sup_{\theta} \mathcal{R}(\theta, \delta)$  je přípustný, pokud existuje a je jednoznačný,
- $\delta^{\pi} = \operatorname{argmin}_{\delta} r(\pi, \delta)$  je přípustný, pokud existuje a je jednoznačný.

**Věta 10.3.** Nechť  $L(\theta, d)$  je ryze konvexní v  $d$  pro  $\forall \theta$ . Mějme  $\delta_0$  jako přípustnou rozhodovací funkci pro  $\tau(\theta)$ , případně přímo  $\theta$ . Mějme  $\delta'$  takovou, že  $\mathcal{R}(\theta, \delta') = \mathcal{R}(\theta, \delta_0)$ ,  $\forall \theta$ . Pak  $\delta' = \delta_0$  s pravděpodobností 1 (s.j.), tedy

$$\mathbb{E}L(\theta, \delta'(X)) = \mathbb{E}L(\theta, \delta_0(X)).$$

*Důkaz.* Sporem:  $\delta_0 \neq \delta'$  s nenulovou pravděpodobností. Sestrojíme  $\delta^* = \frac{\delta_0 + \delta'}{2}$  (je to konvexní kombinace). Pak

$$\begin{aligned} \mathcal{R}(\theta, \delta^*) &= \mathbb{E}L(\theta, \delta^*(X)) = \mathbb{E}\left[L\left(\theta, \frac{\delta_0 + \delta'}{2}\right)\right] \stackrel{\forall \theta}{<} \mathbb{E}\left[\frac{1}{2}L(\theta, \delta_0) + \frac{1}{2}L(\theta, \delta')\right] = \\ &= \frac{1}{2} \underbrace{\mathbb{E}L(\theta, \delta_0)}_{\mathcal{R}(\theta, \delta_0)} + \frac{1}{2} \underbrace{\mathbb{E}L(\theta, \delta')}_{\mathcal{R}(\theta, \delta') = \mathcal{R}(\theta, \delta_0) \forall \theta} = \mathcal{R}(\theta, \delta_0), \quad \forall \theta. \end{aligned}$$

To znamená, že  $\delta^* \ll \delta_0$ , což je spor s přípustností  $\delta_0$ . □



**Věta 10.4.** *Jednoznačná  $\delta^\pi$  je vždy přípustná rozhodovací funkce, pokud existuje. (Část věty 10.2)*

*Důkaz.*  $\delta^\pi$  jednoznačný Bayes, pak


$$\begin{aligned} r(\pi, \delta^\pi) &< r(\pi, \delta), \quad \forall \delta, \\ \mathbb{E}\mathcal{R}(\theta, \delta^\pi) &< \mathbb{E}\mathcal{R}(\theta, \delta), \quad \forall \delta, \\ \int \mathcal{R}(\theta, \delta^\pi) \pi(\theta) d\theta &< \int \mathcal{R}(\theta, \delta) \pi(\theta) d\theta, \quad \forall \delta. \end{aligned}$$

Z toho vyplývá, že existuje bod  $\theta_0$  takový, že  $\mathcal{R}(\theta_0, \delta^\pi) < \mathcal{R}(\theta_0, \delta)$ ,  $\forall \delta$ . Kvůli tomu  $\delta$  nedominuje  $\delta^\pi$ , a proto je  $\delta^\pi$  přípustná.  $\square$

POZNÁMKA 10.5. Pokud  $L(\theta, d)$  je ryze konvexní v  $d$  pro  $\forall \theta$ , pak  $\delta^\pi$  je vždy jednoznačná.

**Věta 10.6.** *Mějme ÚBM,  $X \sim f(x|\theta)$ ,  $\pi(\theta)$ . Nechť  $\pi(\theta) > 0$  pro  $\forall \theta$ , nechť dále  $\delta^\pi$  existuje a  $r(\pi) = r(\pi, \delta^\pi) < +\infty$ . Nechť  $\mathcal{R}(\theta, \delta)$  je spojitá v  $\theta$  pro  $\forall \delta$ . Pak  $\delta^\pi$  je přípustná. (Větu lze ukázat i pro  $r(\pi, \delta^\pi) = +\infty$ )*

*Důkaz.* Sporem. Necht'  $\delta^\pi$  je nepřipustná. Pak by ale existovalo  $\delta_0 \ll \delta^\pi$ , tzn.  $\mathcal{R}(\theta, \delta_0)$  stejnoměrně vylepšuje  $\mathcal{R}(\theta, \delta^\pi)$  a  $\exists \theta_0$  tak, že  $\mathcal{R}(\theta_0, \delta_0) < \mathcal{R}(\theta_0, \delta^\pi)$ , viz obr. 10.2. Potom by ale



Obrázek 10.2: Schéma důkazu.

existovalo okolí  $H_{\theta_0}$  tak, že  $\mathcal{R}(\theta, \delta_0) < \mathcal{R}(\theta, \delta^\pi)$  na  $H_{\theta_0}$ . Potom by platilo, že  $\mathbb{E}^\pi \mathcal{R}(\theta, \delta_0) < \mathbb{E}^\pi \mathcal{R}(\theta, \delta^\pi)$ . To platí, protože  $\pi(\theta) > 0$ ,  $\forall \theta$ . Potom tedy

$$r(\pi, \delta_0) < \underbrace{r(\pi, \delta^\pi)}_{r(\pi) < +\infty},$$

čož je spor s tím, že  $\delta^\pi$  je Bayesovská strategie. V  $\delta^\pi$  totiž dosahuje minima a my jsme našli menší. □

POZNÁMKA 10.7 (Komentář k předpokladu z předchozí věty).

$$\mathcal{R}(\theta, \delta) = \mathbb{E}L(\theta, \delta(X)) = \int_{\mathcal{Y}(\mathbb{R}^n)} L(\theta, \delta(x)) f(x|\theta) \mathrm{d}x.$$

Zde stačí zajistit, aby měl integrand Lebegovskou majorantu, protože chceme  $L$  spojitou v  $\theta$ .

POZNÁMKA 10.8. Doted' jsme hledali podmínky, za kterých je odhad  $\delta^\pi$  přípustný. Nyní budeme hledat možnosti, jak tuto implikaci obrátit.

## 10.2 Historie hledání odhadu pro přípustné funkce

**Stein (1955)** Našel nutnou a postačující podmínku (nebudeme ukazovat jakou), za které jsou všechny přípustné rozhodovací funkce limitami posloupnosti  $\delta^{\pi_n}$  Bayesovských strategií.

**Farrell (1968)** (pro zajímavost) Předpokládáme, že

- 1)  $f(x|\theta)$  spojitá v  $\theta$ ,  $f > 0$  na  $\Theta$ ,
- 2)  $L(\theta, d)$  je ryze konvexní, spojitá,
- 3)  $\forall E \subset \Theta$  kompaktní platí, že

$$\lim_{\|\delta\| \rightarrow +\infty} \inf_{\theta \in E} L(\theta, \delta) = +\infty. \quad (L \text{ je nutně neomezená funkce})$$

Pak libovolná  $\delta_0$  přípustná je limitou  $\delta^{\pi_n}$  Bayesovských strategií.

**Brown (1986)** Předpokládejme, že

- 1)  $L$  ryze konvexní,
- 2)  $f(x|\theta) > 0$ ,  $\mathcal{D}'$  uzavřená a konvexní,
- 3)  $L$  je zdola polospojité (lower semicontinuous), tzn.  $f$  je v  $x_0$  zdola polospojité, pokud  $(\forall \varepsilon > 0)(\exists H_{x_0})(f(x) \geq f(x_0) - \varepsilon)$  na  $H_{x_0}$ .
- 4)  $\lim_{\|\delta\| \rightarrow +\infty} L(\theta, \delta) = +\infty$  ( $L$  je nutně neomezená funkce).

Pak libovolná přípustná strategie je bodovou limitou  $\delta^{\pi_n}$  Bayesovské posloupnosti, kde  $\pi_n(\theta)$  mají omezený support.


**Závěr** Libovolná přípustná strategie  $\delta$  je dosažitelná buď přímo Bayesovským odhadem  $\delta^{\pi}$  nebo zobecněným Bayesovským odhadem  $\delta^{\pi}$ , případně posloupností  $\delta^{\pi_n}$ .

Jak funguje přípustnost u klasických statistických strategií?

**Věta 10.9.** Pokud existuje jednoznačně minimaxní strategie  $\delta_0$ , pak je přípustná.

*Důkaz.* Ponecháno čtenáři. (Obdobně jako ve větě 10.4) □

**Věta 10.10** ("Obrátka"). Nechť  $L(\theta, d)$  je ryze konvexní v  $d$  pro  $\forall \theta$ ,  $\delta_0$  je přípustná rozhodovací funkce, která má konstantní riziko  $\mathcal{R}$ . Pak  $\delta_0$  je jednoznačná minimaxní strategie.




Obrázek 10.3: Schéma důkazu sporem.  $\mathcal{R}(\theta, \delta_0)$  je konstantní a není minimaxní.

*Důkaz.* 1) Ukážeme, že  $\delta_0$  je minimaxní. Sporem. Nechť  $\delta_0$  není minimax, viz obrázek 10.3. Existuje tedy funkce  $\mathcal{R}(\theta, \delta_1)$ , která vylepšuje odhad  $\mathcal{R}(\theta, \delta_0)$ , protože má supremum menší, než hodnota funkce  $\mathcal{R}(\theta, \delta_0)$ . To je spor s přípustností  $\delta_0$ .

- 2) Jednoznačnost sporem. Nechť tedy existuje  $\delta_1 \neq \delta_0$  a přitom  $\delta_1$  je minimaxní. Možnosti:
  - a)  $\mathcal{R}(\theta, \delta_0) = \mathcal{R}(\theta, \delta_1), \forall \theta$ . Ihned získáváme spor díky větě 10.3 ( $\delta_0 = \delta_1$  s.j.), viz obr. 10.4.
  - b)  $\mathcal{R}(\theta, \delta_0)$  konstantní z předpokladu a  $\mathcal{R}(\theta, \delta_1)$  je pod ní, ale mají stejné supremum, což je spor s přípustností  $\delta_0$ , protože jsme našli  $\delta_1$  takovou, že  $\delta_1 \ll \delta_0$ .

□



Obrázek 10.4: Schéma důkazu sporem. Vlevo je znázorněn případ (a), kde  $\mathcal{R}(\theta, \delta_0)$  a  $\mathcal{R}(\theta, \delta_1)$  splývají. Vlevo (b) jsou potom odlišné, ale mají stejné supremum.

### 10.3 Steinův efekt (1955)

Dříve se označoval jako Steinův paradox, ale už se ho podařilo vysvětlit. Mějme tedy běžné statistické  $\mathbf{X} \sim f(\mathbf{x}, \boldsymbol{\theta})$ ,  $\boldsymbol{\theta} \in \Theta \subset \mathbb{R}^k$ ,  $f$  nechť je sféricky symetrické rozdělení okolo  $\boldsymbol{\theta}$ , tzn.  $f(\|\mathbf{x}' - \boldsymbol{\theta}\| + \|\mathbf{x}''\|)$ , kde  $\mathbf{x} = (\mathbf{x}', \mathbf{x}'')$ ,  $\mathbf{x}' \in \mathbb{R}^k$ ,  $\mathbf{x}'' \in \mathbb{R}^{n-k}$ . To splňuje například  $\mathcal{N}_k(\boldsymbol{\theta}, \mathbf{I}_{k \times k})$ . Volme pro  $\boldsymbol{\theta}$  váženou kvadratickou ztrátovou funkci  $L_2^w(\boldsymbol{\theta}, \boldsymbol{\delta}) = \sum_{j=1}^k w_j(\theta_j - \delta_j)^2$ .

Označme  $\boldsymbol{\delta}^*(\mathbf{x}) = (\delta_1^*(\mathbf{x}), \dots, \delta_k^*(\mathbf{x}))$  odhad (rozhodovací funkci) pro  $\boldsymbol{\theta}$  získaný klasickou statistickou procedurou.

Pak  $\exists k_0$  tak, že  $\forall k \geq k_0$  je  $\boldsymbol{\delta}^*$  nepřipustným odhadem (rozhodovací funkce) pro  $\boldsymbol{\theta}$ , přestože  $\delta_j^*$  jsou pro odhad  $\theta_j$  přípustné pro každé  $j \in \hat{k}$ .

**Důsledek 10.11.** *Například klasická rozhodovací funkce metodou jednoznačného minimaxu je od jistého  $k_0$  beznadějná, protože víme (z věty 10.9), že pokud existuje jednoznačný minimax, pak je přípustný. Stein ale říká, že od jistého  $k_0$  se klasickou statistickou procedurou získat přípustné řešení nedá, tzn. od jistého  $k_0$  nemůže existovat jednoznačný minimax. A také stejnoměrně nejlepší strategie  $\delta_U$  od jisté dimenze  $k_0$  neexistuje.*

Co s tím? Místo hledání  $\delta_U = \argmin_{\delta \in \mathcal{D}} \mathcal{R}(\theta, \delta)$ ,  $\forall \theta$  hledá klasická statistika  $\delta_{pu} = \argmin_{\delta \in \mathcal{D}_0 \subset \mathcal{D}} \mathcal{R}(\theta, \delta) \forall \theta$ ,


např.  $\mathcal{D}_0$  nestranné odhady (UMVUE). Tím jsme zajistili existenci, ale pro vysokou dimenzi opět dostaneme nepřipustné řešení. Další možností je použít  $\mathcal{D}'_0$  jako **ekvivariantní** odhady. Ty pak vedou na UMEqE (*Uniformly minimum equivariant estimator*).

Řešení se pak nabízí v podobě Bayese (začlenění apriorní informace  $\pi$ ).

### 10.4 Srovnání přístupů

Tato sekce je brána jako taková poznámka/opakování, které shrnuje některé přístupy z historie.

**1955 Steinův efekt:** Mějme  $X \sim \mathcal{N}_k(\boldsymbol{\theta}, \mathbb{I}_{k \times k})$  a nechť  $\delta_0(\mathbf{x}) = \mathbf{x}$  je ML, minimaxní a víme, že  $\mathcal{R}(\theta, \delta_0) = \text{konst.}$  Do roku 1955 se myslelo, že  $\delta_0$  je jednoznačný minimax  $\forall k$ . Dle věty o jednoznačnosti minimaxu by bylo přípustné  $\forall k$ . Stein však roku 1955 ukázal, že  $\delta_0$  je jednoznačný minimax a přípustný pro  $k = 1, 2$ , a že pro  $(\forall k \geq 3)(\exists \delta')(\delta' \ll \delta_0)$ .



Obrázek 10.5: Kdyby byl  $\mathcal{R}(\theta, \delta_0)$  nejednoznačný minimax, mohl by existovat odhad  $\mathcal{R}(\theta, \delta_1)$ , který ho stejnoměrně vylepšuje, například by byl stejný jen v jednom bodě.

**1961 James-Steinův (shrinkage) odhad parametru polohy:**

$$\delta_{JS}(\mathbf{x}) = \underbrace{\left(1 - \frac{k-2}{\|\mathbf{x}\|^2}\right)}_{\rightarrow -\infty \text{ při } \|\mathbf{x}\| \rightarrow 0^+} \mathbf{x}$$


**1970 Baranchick:**

$$\delta_c^+(\mathbf{x}) = \left(1 - \frac{c}{\|\mathbf{x}\|^2}\right)^+ \mathbf{x} = \begin{cases} \left(1 - \frac{c}{\|\mathbf{x}\|^2}\right) \mathbf{x}, & \text{pokud } c < \|\mathbf{x}\|^2, \\ 0, & \text{jinak,} \end{cases}$$

kde  $c \in [k-2, 2(k-2)]$ . Pak  $\delta_c^+ \ll \delta_{JS} \ll \delta_0$ ,  $\forall k \geq 3$ .

**1994 Shao et al.**  $\exists \delta_S \ll \delta_c^+$ , ale vylepšení už nestojí za tu složitost (tedy Baranchick je kompromis v rámci použitelnosti).

POZNÁMKA 10.12. Pro  $c = 2k-1 \notin [k-2, 2(k-2)]$  je Baranchickova, ale nedominuje  $\delta_{JS}$ ,  $\mathcal{R}(\theta, \delta_{2k-1}^+)$ .



Obrázek 10.6: Sice má odhad  $\mathcal{R}(\theta, \delta_{2k-1}^+)$  maximum vyšší, než  $\mathcal{R}(\theta, \delta_0)$ , ale někdy se vyplatí ho použít, například proto, že chceme předpovídat hodnoty kolem 0 (např. u měření chyb).


**Věta 10.13** (Bergerův jev, 1980).  $\forall k_0 \in \mathbb{N}$  (dimenzi  $\boldsymbol{\theta}$ ), existuje ztrátová funkce  $L(\boldsymbol{\theta}, \mathbf{d})$  taková, že libovolný odhad  $\boldsymbol{\delta}^*(\mathbf{x})$  klasickou statistickou procedurou je  $\forall k \geq k_0$  nepřípustný.

POZNÁMKA 10.14. Připomínka Rao-Blackwellovy věty: Mějme  $L(\theta, d)$  konvexní v  $d$  pro  $\forall \theta$ ,  $\mathbf{T}(\mathbf{X})$  je postačující statistika,  $\delta_0$  je libovolná rozhodovací funkce. Pak

$$\hat{\delta}(\mathbf{t}) = \mathbb{E}[\delta_0(\mathbf{X}) | \mathbf{T}(\mathbf{X}) = \mathbf{t}] \ll \delta_0 \quad \text{a} \quad \mathbb{E}\hat{\delta} = \mathbb{E}\delta_0.$$

**Definice 10.15.** Označme ztrátovou funkci  $L(\theta, \delta | \tau(\theta))$ . Pak rozhodovací funkci  $\delta(\mathbf{x})$  nazýváme **nestrannou** vzhledem k  $L$ , pokud

$$\mathbb{E}L(\theta, \delta | \tau(\theta)) \leq \mathbb{E}L(\theta, \delta | \varphi(\theta)), \quad \forall \varphi, \forall \theta.$$



Obrázek 10.7: Modře jsou vyznačeny nestranné odhady, existují také odhady vyznačeny černě, které nejsou nestranné a mezi nimi i červeně vyznačený odhad, který sice není nestranný, ale stejnoměrně vylepšuje všechny nestranné odhady.

Omezili jsme se na prostor nestranných rizikových funkcí  $\mathcal{D}_0 \subset \mathcal{D}$  vzhledem k  $L$ . Dále  $\delta_U^0 = \underset{\delta \in \mathcal{D}_0}{\operatorname{argmin}} \mathcal{R}(\theta, \delta)$ ,  $\forall \theta$  jako  $\text{UBU}_{LE}$  (*Uniformly best unbiased estimators*), pokud existuje.

Pak

$$L = L_2(\theta, \delta) = (\theta - \delta)^2 \stackrel{\text{případně}}{=} (\tau(\theta) - \delta)^2 \Rightarrow \mathbb{E}L_2(\theta, \delta) = \mathbb{E}(\delta - \mathbb{E}\delta) = D\delta.$$

**Věta 10.16.** Mějme  $L$  konverzní v  $\delta$ ,  $T(\mathbf{X})$  je úplná postačující statistika,  $\delta_0$  nestranná rozhodovací funkce vzhledem k  $L_2$ . Pak  $\hat{\delta}_{R-B}(\mathbf{t})$  je *UMVUE* (potenciálně nepřípustný kvůli Steinovi).

# 11 Grupy transformací, ekvivariantní odhady

## 11.1 Equivariantní rozhodovací funkce (MRE<sub>q</sub>E)

**Definice 11.1.** Mějme grupu  $(G, *)$ , tj. máme k dispozici inverzní prvek, neutrální prvek, atd. Pro každé  $g_1, g_2 \in G$  tedy máme definováno, co to je  $g_1 * g_2$ . Volme speciálně grupu  $(\mathbb{R}, *)$ , potom máme definováno  $g * x$ ,  $\forall g \in G$ ,  $\forall x \in \mathbb{R}$  a také  $g * \mathbf{x}$ ,  $\forall g \in G$ ,  $\forall \mathbf{x} \in \mathbb{R}^n$  (po složkách). Vezmeme pravděpodobnostní model  $X_j = \theta * \varepsilon_j$ , kde  $\varepsilon_j$  značí chyby měření s  $\varepsilon_j \sim \mathbb{P}_{0j}$ ,  $\forall j \in \hat{n}$ . Potom  $\mathbf{X} = (X_j)_{j=1}^n = \theta * \boldsymbol{\varepsilon}$ , kde

$$\boldsymbol{\varepsilon} \sim \prod_{j=1}^n \mathbb{P}_{0j} \stackrel{id}{=} (\mathbb{P}_{01})^n.$$

Dále platí, že

$$\mathbf{X} \sim \mathbb{P}_\theta \in \mathcal{P}_* = \{\mathbb{P}_\theta : \theta \in \Theta \subset \mathbb{R}\}, \quad g \in G \Rightarrow g * \mathbf{X} = g * (\theta * \boldsymbol{\varepsilon}) = (g * \theta) * \boldsymbol{\varepsilon} \sim \mathbb{P}_{g*\theta} \in \mathcal{P}_*.$$

**Definice 11.2.** Rozhodovací funkce  $\delta$  se nazývá **ekvivariantní** pro  $\theta$  vzhledem ke grupě  $(G, *)$ , pokud platí, že

$$\delta(g * \mathbf{x}) = g * \delta(\mathbf{x}), \quad \forall g \in G, \quad \forall \mathbf{x} \in \chi(\mathbb{R}^n).$$

**Definice 11.3.** Ztrátová funkce  $L(\theta, d)$  se nazývá **invariantní** vzhledem ke grupě  $(G, *)$ , pokud

$$L(g * \theta, g * \delta(x)) = L(\theta, \delta(x)) \quad \forall \theta, \forall g, \forall \delta.$$

**Důsledek 11.4.**

$$\begin{aligned} L(\theta, \delta) &\stackrel{\forall g}{=} L(g * \theta, g * \delta) = \left| \begin{array}{l} \text{volme } g = \tilde{\theta} \text{ inverzní prvek v } (G, *) \\ \text{tzn. } \tilde{\theta} * \theta = I/O \text{ neutrální prvek v } (G, *) \end{array} \right| = L(\tilde{\theta} * \theta, \tilde{\theta} * \delta) = \\ &= L(I/O, \tilde{\theta} * \delta) =: \varrho(\tilde{\theta} * \delta), \quad \forall \theta, \forall \delta. \end{aligned}$$

Značení  $I/O$  se používá proto, že např. pro operaci  $+$  je to 0, kdežto pro  $\cdot$  je to 1.

**Důsledek 11.5.**

$$\begin{aligned} \mathcal{R}(\theta, \delta) &= \mathbb{E}_\theta L(\theta, \delta(\mathbf{X})) \stackrel{inv. L}{=} \mathbb{E}_{\theta \varrho}(\tilde{\theta} * \delta(\mathbf{X})) = \left| \begin{array}{l} \mathbf{X} = \theta * \boldsymbol{\varepsilon} \\ \boldsymbol{\varepsilon} \sim \mathbb{P}_0 \end{array} \right| = \mathbb{E}_{\mathbb{P}_0 \varrho}(\tilde{\theta} * \delta(\theta * \boldsymbol{\varepsilon})) \stackrel{\delta \text{ ekvi.}}{=} \\ &= \mathbb{E}_{\mathbb{P}_0 \varrho}(\tilde{\theta} * \theta * \delta(\boldsymbol{\varepsilon})) = \mathbb{E}_{\mathbb{P}_0 \varrho}(I/O * \delta(\boldsymbol{\varepsilon})) = \text{konst v } \theta, \quad \forall \theta, \end{aligned}$$

tedy nezávisí na  $\theta$ . Hledá se proto jednodušší odhad s nejmenším rizikem (mezi ekvivariantními). Vezme se takový odhad, který má nejmenší hodnotu rizikové funkce.

**Definice 11.6.** Definujeme MRE<sub>q</sub>E Minimum risk equivariant estimator jako

$$\delta^* := \underset{\delta \in \mathcal{D}_{Eq}}{\operatorname{argmin}} \mathcal{R}(\theta, \delta), \quad \forall \theta.$$

## 11 Grupy transformací, ekvivariantní odhady

Takový odhad ale nemusí být přípustný a nemusí ani existovat.

POZNÁMKA 11.7. Bayesovské řešení  $\widehat{\delta}_B = \operatorname{argmin}_{\delta} r(\pi, \delta)$  nebo  $\widehat{\delta}_B(\mathbf{x}) = \operatorname{argmin}_{\delta(\mathbf{x})} \varrho(\pi, \delta|\mathbf{x})$ , kde  $\varrho(\pi, \delta|\mathbf{x})$ , se nazývá **aposteriorní Bayesovské riziko** a splňuje (toto  $\varrho$  není to stejné jako v textu výše)

$$\varrho(\pi, \delta|\mathbf{x}) = \mathbb{E}^{\pi}[L|\mathbf{x}] = \int L(\theta, \delta) \pi(\theta|\mathbf{x}) d\theta = \int L(\theta, \delta) \frac{f\pi(\theta)}{\int f\pi(\theta) d\theta} d\theta.$$

Zde stačí volit  $\pi(\theta) = 1$  na  $\Theta$  (potenciálně nevlastní). Pokud zvolíme konkrétně  $L = L_2$ , pak  $\delta^*(\mathbf{x}) = \frac{\int \theta f(\mathbf{x}-\theta) d\theta}{\int f(\mathbf{x}-\theta) d\theta}$ , což se nazývá **Pitmanův odhad**.

PŘÍKLAD 11.8. Volme  $(G, *) = (\mathbb{R}, +)$ , tedy  $g * \mathbf{x} = (x_1 + g, \dots, x_n + g) = g + \mathbf{x}$ . Pravděpodobnostní model se nazývá model s měřítkem (*Location family*) (např.  $\mathcal{N}(\mu, \sigma^2)$  známé), pokud

$$\begin{aligned} X_j &= \theta + \varepsilon_j \quad (\text{aditivní chyba}), \\ \mathbf{X} &= \theta + \boldsymbol{\varepsilon} \sim \mathbb{P}_{\theta} \text{ a platí, že} \\ g * \mathbf{X} &= g + \mathbf{X} \sim \mathbb{P}_{g+\theta}. \end{aligned}$$

$\delta$  je ekvivariantní, pokud  $\delta(g + \mathbf{x}) = g + \delta(\mathbf{x})$ . Například  $\delta(\mathbf{x}) = \frac{1}{n} \sum_{j=1}^n X_j$  (nebo také  $\delta(\mathbf{x}) = x_{\text{medián}}$ ) je ekvivariantní rozhodovací funkce, protože

$$\delta(g + \mathbf{x}) = \frac{1}{n} \sum_{j=1}^n (X_j + g) = \frac{1}{n} \sum_{j=1}^n X_j + g = \delta(\mathbf{x}) + g.$$

$L$  je invariantní, pokud

$$L(\theta, \delta) = \varrho(\tilde{\theta} * \delta) = \varrho(\delta - \theta) \stackrel{\text{např.}}{=} (\delta - \theta)^2 = L_2.$$

Máme tedy zajištěno, že  $\mathcal{R}(\theta, \delta_{Eq}) = \text{konst}$  v  $\theta$ .

Závěr: Existuje procedura pro hledání  $MRE_q E$  pro  $(G, *) = (\mathbb{R}, +)$  ve tvaru

$$\delta^*(\mathbf{x}) = \operatorname{argmin}_{\delta \in \mathcal{D}_{Eq}} \frac{\int \varrho(\delta - \theta) f(\mathbf{x} - \theta) d\theta}{\int f(\mathbf{x} - \theta) d\theta} = \delta_B^{\pi=1}(\mathbf{x}).$$

PŘÍKLAD 11.9. Mějme  $\varepsilon_j \sim iid \operatorname{Exp}(1)$ ,  $f(\mathbf{x}-\theta) = e^{-\sum_{j=1}^n x_j + n\theta}$ , pokud  $\theta < x_{(1)} = \min\{(x_j)_1^n\}$ . Dále pak

$$\delta^*(\mathbf{x}) \stackrel{L_2}{=} \dots = x_{(1)} - \frac{1}{n},$$

což je Pitmanův odhad pro  $\operatorname{Exp}(1)$ , tedy  $MRE_q E$ .

## 12 Bayesovské odhady pro kvadratickou a multilineární L

POZNÁMKA 12.1 (Opakování vyhazovací věty 9.12). Mějme ÚBM,  $X \sim f_X(x|\theta)$ ,  $\pi(\theta) \sim \theta$ ,  $L = L_2$ . Pokud  $0 < \mathbb{E}(\theta^2|\mathbf{x}) < +\infty$ , pak

$$\delta^\pi(\mathbf{x}) = \mathbb{E}^\pi(\theta|\mathbf{x})$$

a Bayesovské riziko je

$$r(\pi) = \mathbb{E}^m[\mathbb{D}^\pi(\theta|\mathbf{x})].$$

**Věta 12.2.** Mějme  $f_X$ ,  $\pi(\theta)$ ,  $L_2^w(\theta, \delta) := w(\theta)(\theta - \delta)^2$ . Pokud  $0 < \mathbb{E}[\theta^2 w(\theta)|\mathbf{x}] < +\infty$ , pak

$$\delta^\pi(\mathbf{x}) = \frac{\mathbb{E}^\pi[\theta w(\theta)|\mathbf{x}]}{\mathbb{E}^\pi[w(\theta)|\mathbf{x}]}$$

a  $r(\pi) = c \cdot \mathbb{E}^{m_w}[\mathbb{D}^{\pi_w}(\theta|\mathbf{x})]$ , kde  $m_w^{(*)}$  a  $\pi_w(\theta|\mathbf{x})$  jsou marginální rozdělení  $\mathbf{X}$  a  $\theta|\mathbf{x}$  příslušné  $\pi_w(\theta) = \frac{\pi(\theta)w(\theta)}{c}$ ,  $c = \int \pi w d\theta$ .

Důkaz.

$$\begin{aligned} r_w(\pi, \delta) &\stackrel{L_2^w}{=} \mathbb{E}^\pi[\mathbb{E}^f[L_2^w(\theta, \delta(\mathbf{X}))]] = \int_{\Theta} \left( \int_{\chi(\mathbb{R}^n)} w(\theta)(\theta - \delta(\mathbf{x}))^2 f(\mathbf{x}|\theta) d\mathbf{x} \right) \pi(\theta) d\theta = \\ &= \int_{\Theta} \mathbb{E}^f[L_2(\theta, \delta(\mathbf{X}))] \underbrace{\pi(\theta)w(\theta)}_{\propto \pi_w(\theta) \cdot c} d\theta = c \cdot \mathbb{E}^{\pi_w} \underbrace{\mathbb{E}^f(L_2)}_{\mathcal{R}(\theta, \delta)} = c \cdot r_2(\pi_w, \delta). \end{aligned}$$

Ukázali jsme tedy, že

$$\delta^\pi = \operatorname{argmin}_{\delta} r_w(\pi, \delta) = \operatorname{argmin}_{\delta} r_2(\pi_w, \delta) \stackrel{12.1}{=} \mathbb{E}^{\pi_w}(\theta|\mathbf{x}) = \dots = \frac{\mathbb{E}^\pi[\theta w(\theta)|\mathbf{x}]}{\mathbb{E}^\pi[w(\theta)|\mathbf{x}]}$$

kde aposteriorní rozdělení  $\pi_w(\theta|\mathbf{x})$  příslušné apriorní hustotě  $\pi_w(\theta)$ . Dále  $r(\pi) \stackrel{12.1}{=} \mathbb{E}^{m_w} \mathbb{D}^{\pi_w}(\theta|\mathbf{x})$ .  $\square$

POZNÁMKA 12.3. •  $w(\theta)$  se zde přidává, protože například můžeme chtít, aby byl odhad v okolí nuly opravdu dobrý, ale vzdálené body nás nezajímají.

- Pokud je  $\delta^\pi$  jednoznačný, potom je přípustný. Pokud  $\mathcal{R}(\theta, \delta)$  je spojitá v  $\theta$  a  $\pi > 0$ , potom je  $\delta^\pi$  přípustná. Přípustná  $\delta^\pi$  není ovlivněna  $w(\theta)$  v  $L_2^w$  (robustnost  $\delta^\pi$  z hlediska volby váhy).

**Věta 12.4** (Vyhazovací 2). Mějme  $\{f(x|\theta) : \theta \in \Theta \subset \mathbb{R}^k\}$ ,  $\theta \sim \pi(\theta)$ ,  $L = L_2^Q(\theta, \delta) = (\theta - \delta)^T \mathbf{Q}(\theta - \delta)$ , kde  $\mathbf{Q}$  je PD matice o rozměru  $k \times k$  a  $\mathbf{Q}$  nezávisí na  $\theta$ . Nechť  $\mathbb{Cov}(\theta|\mathbf{x})$  je konečná (ideálně regulární) a nenulová. Pak pro Bayesovské řešení platí, že  $\delta^\pi(\mathbf{x}) = \mathbb{E}^\pi(\theta|\mathbf{x})$ .

Důkaz. Obdobně jako v  $\mathbb{R}^1$  (viz 9.12).  $\square$

POZNÁMKA 12.5. a)  $\delta^\pi$  nezávisí na tvaru  $\mathbf{Q}$ , tzn. volíme  $\mathbf{Q} = \mathbf{I}$ , tedy  $L_2^Q = \sum_{i=1}^k (\theta_i - \delta_i)^2$ , a nemusíme proto užívat  $L_2^Q = \sum_i \sum_j q_{ij}(\theta_i - \delta_i)(\theta_j - \delta_j)$ .

b)  $L_2^{Q,w}(\theta, \delta) = \sum_1^k w_i(\theta) \cdot (\theta_i - \delta_i)^2$ . V tomto případě tedy věta 12.4 neplatí!



## 12.1 Další volby $L$


$L_2$  není robustní na odchylky (1964 Huber, Hampel, Ronchetti), což někdy může být problém. Historicky se proto začaly zkoušet jiné ztrátové funkce, například obecněji  $L_p = (\theta - \delta)^p$ ,  $p \in (1, 2)$ . Najednou ale nevíme, v jakém tvaru bude  $\delta^\pi$ . Víme, že podle definice je

$$\delta^\pi = \underset{\delta}{\operatorname{argmin}} \underbrace{r(\pi, \delta)}_{\mathbb{E}^\pi \mathbb{E} f L} \stackrel{\forall \mathbf{x}}{=} \underset{\delta(\mathbf{x})}{\operatorname{argmin}} \underbrace{\int L(\theta, \delta(\mathbf{x})) \pi(\theta | \mathbf{x}) d\theta}_{\mathbb{E}^\pi(L | \mathbf{x})} = \underset{\delta(\mathbf{x})}{\operatorname{argmin}} \varrho(\pi, \delta | \mathbf{x}),$$

kde  $\varrho$  je aposteriorní Bayesovské riziko. Takový způsob ale vede na minimalizaci integrálu, což většinou není možné vyřešit.

**Věta 12.6.** Mějme  $f(x|\theta)$ ,  $\pi(\theta)$ ,  $L_1(\theta, \delta) := |\theta - \delta|$ . Necht'  $0 < \mathbb{E}[|\theta| | \mathbf{x}] < +\infty$ , pak  $\delta^\pi(\mathbf{x}) = \pi_{1/2}(\theta | \mathbf{x})$ , což je medián aposteriorního rozdělení.

*Důkaz.* Viz obecnější důkaz věty 12.7 □



Obrázek 12.1: Vyznačení mediánu aposteriorní hustoty.

**Věta 12.7.** Mějme  $f$ ,  $\pi$ ,  $L = L_{k_1, k_2}(\theta, d) = \begin{cases} k_1(d - \theta), & d \geq \theta, \\ k_2(\theta - d), & d < \theta. \end{cases}$  (multilineární loss). Necht'  $0 < \mathbb{E}(|\theta| | \mathbf{x}) < +\infty$ . Pak  $\delta^\pi(\mathbf{x}) = \pi_{\frac{k_2}{k_1 + k_2}}(\theta | \mathbf{x})$ , což je  $\frac{k_2}{k_1 + k_2}$ -kvantil aposteriorního rozdělení.

*Důkaz.* Spočítáme si, jak vypadá aposteriorní Bayesovské riziko:

$$\begin{aligned} \varrho(\pi, \delta | \mathbf{x}) &= \mathbb{E}^\pi[L_{k_1, k_2}(\theta, \delta(\mathbf{x})) | \mathbf{x}] = k_1 \int_{-\infty}^{\delta} (\delta - \theta) \pi(\theta | \mathbf{x}) d\theta + k_2 \int_{\delta}^{+\infty} (\theta - \delta) \pi(\theta | \mathbf{x}) d\theta \stackrel{P.P.}{=} \\ &= k_1 \left( [(\delta - \theta) F_\pi(\theta | \mathbf{x})]_{-\infty}^{\delta} + \int_{-\infty}^{\delta} F_\pi(\theta | \mathbf{x}) d\theta \right) + k_2 \cdot (\dots) = \\ &= k_1 \left( 0 - \underbrace{\delta \cdot F_\pi(-\infty | \mathbf{x})}_0 + \underbrace{\lim_{\theta \rightarrow -\infty} \theta F_\pi(\theta | \mathbf{x})}_0, \text{ protože } \int_{\Theta} |\theta| \pi(\theta | \mathbf{x}) < \infty \right) + \int_{-\infty}^{\delta} F_\pi(\theta | \mathbf{x}) d\theta + k_2 \cdot (\dots) = \\ &= k_1 \int_{-\infty}^{\delta} F_\pi(\theta | \mathbf{x}) d\theta + k_2 \int_{\delta}^{+\infty} (1 - F_\pi(\theta | \mathbf{x})) d\theta. \end{aligned}$$

Využíváme vztahu  $\lim_{\theta \rightarrow +\infty} \theta F_\pi(\theta | \mathbf{x}) = 0 = \lim_{\theta \rightarrow +\infty} \theta (1 - F_\pi(\theta | \mathbf{x}))$ , který platí díky předpokladu. Proto pak

$$\varrho'_\delta = k_1 \cdot 1 \cdot F_\pi(\delta | \mathbf{x}) + k_2 \cdot (-1) (1 - F_\pi(\delta | \mathbf{x})) = 0,$$

z toho

$$F_{\pi}(\delta|\mathbf{x}) = \frac{k_2}{k_1 + k_2} \in (0, 1), \quad \text{a proto } \delta(\mathbf{x}) = \pi_{\frac{k_2}{k_1 + k_2}}(\theta|\mathbf{x}).$$

□

**Věta 12.8.** *Mějme  $f, \pi, L_{\{0,1\}}(\theta, \delta) \stackrel{\text{ozn}}{=} L_{0,1}(\theta, \delta) = \begin{cases} 0, & |\theta - \delta| \leq c, \\ 1, & |\theta - \delta| > c. \end{cases}$ . Pak Bayesovské řešení  $\delta^{\pi}(\mathbf{x})$  je středem intervalu  $I_{2c}$  délky  $2c$ , který maximalizuje  $\mathbb{P}^{\pi}(\theta \in I_{2c}|\mathbf{x})$ .*

*Důkaz.* Přenecháno čtenáři (Zkouškový důkaz).

Nápověda: Vyjít z  $\varrho(\pi, \delta(\mathbf{x})|\mathbf{x})$  a vyrobit tam argmin  $\varrho$ .

□

**Definice 12.9.** Definujeme **maximum a posteriori odhad rozhodovací funkce** (někdy také Bayesovská maximálně věrohodný odhad) vztahem  $\delta_{\text{MAP}}(\mathbf{x}) := \operatorname{argmax}_{\theta} \pi(\theta|\mathbf{x})$  nebo alternativně, pokud  $\int f \cdot \pi \, d\theta = +\infty$ , definujeme vztahem  $\delta_{\text{MAP}}(\mathbf{x}) := \operatorname{argmax}_{\theta} f(\mathbf{x}|\theta)\pi(\theta)$ .

# 13 Výpočetní aspekty Bayesovských metod

Obecně, když hledáme Bayesovské řešení pro naše naměřená data  $\mathbf{x}$ , provádíme

$$\operatorname{argmin}_{\delta \in \mathcal{D}} \varrho(\pi, \delta | \mathbf{x}) \propto \int_{\Theta} L(\theta, (\delta(\mathbf{x}))) \pi(\theta) f(\mathbf{x} | \theta) d\theta,$$

což je možné počítat numerickými metodami. Pro  $L_2$  jsme však ukázali, že umíme  $\delta$  najít ve tvaru

$$\delta^\pi(\mathbf{x}) = \mathbb{E}^\pi[\tau(\theta) | \mathbf{x}] = \frac{\int_{\Theta} \tau(\theta) \pi(\theta) f(\mathbf{x} | \theta) d\theta}{\int_{\Theta} \pi(\theta) f(\mathbf{x} | \theta) d\theta},$$

na což je opět možné použít numerické metody a získat tedy alespoň aproximaci řešení. Pro  $L_1$  ztrátové funkce pak můžeme získat (opět např. numericky) odhad

$$\delta^\pi(\mathbf{x}) = \pi_{1/2}(\theta | \mathbf{x}).$$

Hledáme tedy  $\pi_{1/2}$  takové, že

$$\frac{1}{2} = \int_{-\infty}^{\pi_{1/2}} \pi(\theta | \mathbf{x}) d\theta = \int_{-\infty}^{\pi_{1/2}} \pi(\theta) f(\mathbf{x} | \theta) d\theta.$$

Pro  $L_{0,1}$  pak hledáme

$$\delta^\pi(\mathbf{x}) = \operatorname{argmax}_{\theta} \pi(\theta) f(\mathbf{x} | \theta),$$

což opět není snadná úloha, i když dnes existují metody, jak to počítat.

## 13.1 Numerická integrace

Existuje mnoho metod, pomocí kterých se dají již zmíněné integrály vypočítat. Za zmínku stojí např. Simpson, Aproximace na základě vhodných OG bází, Aproximace wavelety, metoda Monte Carlo, Laplaceova asymptotická aproximace apod. Zajímavé jsou tzv. Polynomiální kvadratury (Gauss, Newton-Costes,...), které postupují následovně:

$$\int_{\Theta} \tau(\theta) \pi(\theta) f(x | \theta) d\theta \sim \int_{-\infty}^{+\infty} e^{-t^2/2} f(t) dt \approx \sum_{i=1}^n w_i f(t_i),$$

kde

$$w_i = \frac{2^{n-1} n! \sqrt{n}}{n^2 [H_{n-1}(t_i)]^2}.$$

Zde označujeme  $t_i$  jako uzly v  $[a, b]$  a  $w_i$  jako váhy. Potom  $t_i$  je  $i$ -tý kořen  $H_n(t)$  jakožto Hermitovského polynomu.

# 14 Bayesovská strategie testování hypotéz

Testujeme hypotézy  $H_0 : \theta \in \Theta_0$  vs.  $H_1 : \theta \in \Theta_1$ , kde  $\Theta = \Theta_0 \sqcup \Theta_1$ . Známujeme  $\theta \sim \pi(\theta)$ , kde  $\pi(\theta)$  jako vždy představuje apriorní informaci (vlastní/nevlastní/konstantu). Oproti klasické statistice je testování u Bayesovské statistiky o poznání jednodušší. Vždy jsme totiž museli najít kritický obor  $W$  a zkoumali jsme, zda-li se v ní nachází naše naměřená data. Nezkoumali jsme tedy vlastně pravděpodobnost, že zkoumaná hypotéza platí, ale spíše pravděpodobnost, že data padly do kritického oboru.

V Bayesovské statistice se však rovnou ptáme na pravděpodobnost, že daná hypotéza platí. Máme tedy

**Apriorní test  $H_0$ :**  $H_0$  přijmeme, pokud  $\mathbb{P}^\pi(H_0) = \mathbb{P}^\pi(\theta \in \Theta_0) \stackrel{?}{>} \frac{1}{2}$  (můžeme nastavit i jiný threshold, než  $1/2$ ).

**Aposteriorní test  $H_0$ :** Máme  $\pi(\theta)$ , naměříme data  $\mathbf{X} \sim f_{\mathbf{X}}$  a z toho získáme  $\pi(\theta|\mathbf{x})$ . Poté můžeme spočítat pravděpodobnost, že platí  $H_0$  jako

$$\mathbb{P}^\pi(H_0|\mathbf{x}) = \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}) \stackrel{?}{>} \frac{1}{2}, \text{ což je vlastně } \int_{\Theta_0} \pi(\theta|\mathbf{x}) d\theta \leq \frac{1}{2},$$

$$\text{kde } \pi(\theta|\mathbf{x}) = \frac{f_{\mathbf{X}}(\theta|\mathbf{x})}{\int_{\Theta} f_{\mathbf{X}}(\theta|\mathbf{x}) d\theta}.$$

Vezmeme tedy rozhodovací prostor  $\mathcal{D} = \{0, 1\} = \{\text{no } H_0, \text{ yes } H_0\}$  a nastavujeme parametrickou funkci

$$\tau(\theta) = I_{\Theta_0} = \begin{cases} 1, & \theta \in \Theta_0 \text{ (} H_0 \text{ platí)}, \\ 0, & \theta \in \Theta_1 \text{ (} H_1 \text{ platí)}. \end{cases}$$

S ní přišel Neyman s Pearsonem (a Fisherem) už kolem roku 1950. Nyní ale ukážeme, že tato na první pohled slibná metoda je vlastně špatná a vede na tzv. Jeffreys-Lindleyův paradox.

**Věta 14.1.** *Volme ztrátovou funkci ( $a_0, a_1 > 0$ )*

$$L_{a_0, a_1}(\theta, \delta) = \begin{cases} 0, & \delta = I_{\Theta_0}(\theta) = \tau(\theta) \text{ (trefa)}, \\ a_0, & \theta \in \Theta_0(H_0) \wedge \delta = 0 \text{ (chyba I. druhu)}, \\ a_1, & \theta \in \Theta_1(H_1) \wedge \delta = 1 \text{ (chyba II. druhu)}. \end{cases}$$

Potom

$$\delta^\pi = \begin{cases} 1, & \text{pokud } \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}) > \frac{a_1}{a_0 + a_1}, \\ 0, & \text{pokud } \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}) \leq \frac{a_1}{a_0 + a_1}, \end{cases}$$

kde  $\frac{a_1}{a_0 + a_1} = \frac{1}{1 + \frac{a_0}{a_1}}$  je závislá na poměru  $\frac{a_0}{a_1}$ . Pro  $a_0 = a_1 = 1$  je pak hranice  $\frac{1}{2}$ .

*Důkaz.* Vezmeme aposteriorní Bayesovské riziko (za  $L$  bereme  $L_{a_0, a_1}(\theta, \delta)$ )

$$\begin{aligned} \rho(\pi, \delta|\mathbf{x}) &= \mathbb{E}^\pi[L(\theta, \delta(\mathbf{x}))|\mathbf{x}] = 0 \cdot \mathbb{P}^\pi(\dots) + a_0 \cdot \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}) \cdot I_{\{0\}}(\delta) + a_1 \cdot \mathbb{P}^\pi(\theta \in \Theta_1|\mathbf{x}) \cdot I_{\{1\}}(\delta) = \\ &= \begin{cases} a_0 \cdot \mathbb{P}^\pi(\theta \in \Theta_0|\mathbf{x}), & \text{pokud } \delta(\mathbf{x}) = 0, \\ a_1 \cdot \mathbb{P}^\pi(\theta \in \Theta_1|\mathbf{x}), & \text{pokud } \delta(\mathbf{x}) = 1. \end{cases} \end{aligned}$$

Z toho vyplývá, že

$$\delta^\pi(\mathbf{x}) = \underset{\delta}{\operatorname{argmin}} \varrho = \begin{cases} 1 & \text{pokud } a_1 \mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x}) < a_0 \mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x}), \\ 0 & \text{pokud } a_1 \mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x}) \geq a_0 \mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x}), \end{cases}$$


kde horní řádek přepíšeme na

$$a_1 \mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x}) = a_1 (1 - \mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x})) < a_0 \mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x}),$$

z čehož spočítáme

$$\mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x}) > \frac{a_1}{a_0 + a_1}.$$

□



Obrázek 14.1: Význam Bayesovského testování  $H_0$  oproti  $H_1$ . Vypočítáme tedy pravděpodobnost, že se parametr  $\theta$  nachází v intervalu  $\Theta_0$  a zjistíme, jestli je tato hodnota větší, než  $\frac{a_1}{a_0 + a_1}$ . (Spočítáme plochu aposteriorní hustoty nad intervalem  $\Theta_0$ .)

POZNÁMKA 14.2. Bayes umožňuje symetrizovat rozhodovací úlohu ( $a_0 = a_1$ ) nebo penalizovat v závislosti na úloze, experimentu nebo "datech".

Bayesovské testování hypotéz se vyhýbá nutnosti nastavení  $\alpha \in (0, 1)$ , kde  $\alpha$  ovlivňuje  $\beta$  sílu testu.

**Definice 14.3.** Definujeme **Bayesovský faktor** jako

$$B^\pi(\mathbf{x}) := \frac{\frac{\mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x})}{\mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x})}}{\frac{\mathbb{P}^\pi(\theta \in \Theta_0)}{\mathbb{P}^\pi(\theta \in \Theta_1)}}.$$

POZNÁMKA 14.4. Říká nám, jaký je vliv dat  $\mathbf{x}$  na testování hypotéz oproti tomu, když  $\mathbf{x}$  vůbec nepoužijí. Pokud  $B^\pi(\mathbf{x}) > 1$ , tak se data oproti apriornímu testování spíše přiklání k  $H_0$ . Pokud by ovšem vyšlo například velmi vysoké číslo, neznamena to nutně, že přijímáme hypotézu  $H_0$ , protože tato hodnota je jen relativní příklon k hypotéze  $H_0$  oproti apriornímu testování.

POZNÁMKA 14.5. Mějme například  $\Theta_0 = \{\theta_0\}$  a  $\Theta_1 = \{\theta_1\}$  jednoprvkové. Potom

$$\mathbb{P}^\pi(\theta \in \Theta_0) = \mathbb{P}(\theta = \theta_0) =: \pi_0, \quad \mathbb{P}^\pi(\theta \in \Theta_1) = \mathbb{P}(\theta = \theta_1) =: \pi_1$$

a

$$\mathbb{P}^\pi(\theta = \theta_0 | \mathbf{x}) = \pi(\theta_0 | \mathbf{x}) = \frac{f_0 \pi_0}{f_0 \pi_0 + f_1 \pi_1}, \quad \mathbb{P}^\pi(\theta = \theta_1 | \mathbf{x}) = \pi(\theta_1 | \mathbf{x}) = \frac{f_1 \pi_1}{f_0 \pi_0 + f_1 \pi_1}.$$

Z toho pak  $B^\pi(\mathbf{x}) = \frac{\frac{f_0 \pi_0}{f_1 \pi_1}}{\frac{\pi_0}{\pi_1}} = \frac{f_0}{f_1} = \frac{L_0}{L_1}$ , což je věrohodnostní poměr - *Likelihood ratio*.

## 14 Bayesovská strategie testování hypotéz

Pro obecnou úlohu označme  $\varrho_0 := \mathbb{P}^\pi(\theta \in \Theta_0)$  a  $\varrho_1 := \mathbb{P}^\pi(\theta \in \Theta_1) = 1 - \varrho_0$ . Přijímáme  $H_0$ , tedy  $\delta(\mathbf{x}) = 1$ , pokud

$$a_1 \cdot \mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x}) < a_0 \cdot \mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x}).$$

Potom po úpravě a vydělení  $\frac{\varrho_0}{\varrho_1}$  dostáváme

$$\frac{\frac{a_1}{a_0}}{\frac{\varrho_0}{\varrho_1}} < \frac{\frac{\mathbb{P}^\pi(\theta \in \Theta_0 | \mathbf{x})}{\mathbb{P}^\pi(\theta \in \Theta_1 | \mathbf{x})}}{\frac{\varrho_0}{\varrho_1}} = B^\pi(\mathbf{x}).$$

Pro rozhodování o  $H_0$  tedy můžeme použít Bayesovský faktor, ale v tomto formátu.

**POZNÁMKA 14.6** (Sekvenční Bayesovské testování hypotéz). Máme apriorní pravděpodobnosti  $\varrho_0, \varrho_1$ , naměříme data  $\mathbf{x}$ . Z toho pak vyrobíme aposteriorní hustotu  $\pi(\theta | \mathbf{x})$ , a pak se rozhodujeme mezi  $H_0$  a  $H_1$ . Poté můžeme sekvenčně pokračovat dál tak, že vezmeme  $\tilde{\pi}(\theta) = \pi(\theta | \mathbf{x})$  a naměříme další data  $\tilde{\mathbf{x}} \sim \tilde{f}$ . Potom získáme aposteriorní hustotu  $\tilde{\pi}(\theta | \tilde{\mathbf{x}}, \mathbf{x})$  a rozhodneme se mezi  $H_0$  a  $H_1$ . Znovu můžeme sekvenčně pokračovat tak, že  $\tilde{\tilde{\pi}}(\theta) = \tilde{\pi}(\theta | \tilde{\mathbf{x}}, \mathbf{x})$  a pokračujeme dále analogicky.

### 14.1 Aspekt Bayesovského testování hypotéz

Testujeme  $H_0 : \theta = \theta_0$  vs.  $H_1 : \theta \neq \theta_0$ . Nastavíme  $\theta \sim \pi(\theta)$  a předpokládáme, že je tato hustota spojitá. Ve spojitém modelu je pravděpodobnost, že náhodná veličina  $\theta$  nabude jedné izolované hodnoty, nulová, tedy

$$\varrho_0 = \mathbb{P}^\pi(\theta = \theta_0) = 0 \quad \Rightarrow \quad \mathbb{P}^\pi(\theta = \theta_0 | \mathbf{x}) = \frac{f_0 \pi_0}{c} = 0.$$


Totéž se dá analogicky ukázat pro 1. Z toho zároveň vyplývá, že  $\varrho_0 = \begin{cases} 0 \\ 1 \end{cases}$  je absorbuující stav, protože se z něj nedostaneme, ať už naměříme libovolná nová data. Dále víme, že  $\pi(\theta)$  je konstantní, tudíž nepreferujeme žádnou konkrétní hodnotu  $\theta \in \Theta$ .

**PŘÍKLAD 14.7.** Mějme  $H_0$  hypotézu, že zítra bude pršet s pravděpodobností rovnu 0.7 a  $H_1$  jako  $\neq 0.7$ . Toto testování nemá smysl, protože např.  $0.700001 \neq 0.7$  a není možné při kvalitních datech testovat jednu hodnotu z celého kontinua.

Jak na to? Buďto můžeme testovat interval ve tvaru

$$H_0 : \theta \in (\theta_0 - \varepsilon, \theta_0 + \varepsilon) \text{ vs. } H_1 : \theta \notin (\theta_0 - \varepsilon, \theta_0 + \varepsilon),$$

nebo můžeme volit  $\pi(\theta) = \varrho_0 \cdot \delta_{\theta_0} + (1 - \varrho_0) \cdot \pi_1(\theta)$ , kde  $\varrho_0$  volíme větší než 0 (to si nastavujeme sami), případně menší než 1 (pak  $\varrho_1 = 1 - \varrho_0$ ), a  $\delta$  značí Diracovo  $\delta$ , viz obr. 14.2.



Obrázek 14.2: Hodnota  $\varrho_0$  vyjadřuje pravděpodobnost, že věříme právě této hodnotě  $\theta_0$ , a na zbytku definičního oboru máme k dispozici apriorní hustotu  $\pi_1(\theta)$ . Tímto způsobem tedy vkládáme do BTH dodatečnou apriorní informaci.

## 14 Bayesovská strategie testování hypotéz

Při takto upravené apriorní hustotě můžeme spočítat aposteriorní hustotu jako

$$\begin{aligned}\pi(\theta_0|\mathbf{x}) &= \mathbb{P}^\pi(\theta = \theta_0|\mathbf{x}) = \frac{f_0 \cdot \pi(\theta_0)}{\int_{\Theta} f_X \cdot \pi \, d\theta} = \frac{f_0 \cdot \varrho_0}{f_0 \cdot \varrho_0 + (1 - \varrho_0) \underbrace{\int_{\Theta_1} f \cdot \pi(\theta) \, d\theta}_{m_1(\mathbf{x})}} = \\ &= \left[ 1 + \frac{1 - \varrho_0}{\varrho_0} \frac{m_1(\mathbf{x})}{f_0(\mathbf{x})} \right]^{-1} < \frac{a_1}{a_0 + a_1}.\end{aligned}$$

Z toho se dá potom vypočítat Bayesovský faktor jako  $B^\pi(\mathbf{x}) = \frac{f_0(\mathbf{x})}{m_1(\mathbf{x})}$ .

**PŘÍKLAD 14.8.** Mějme  $X \sim \mathcal{N}(\mu, 1)$  a chceme testovat  $H_0 : \mu = 0$  vs.  $H_1 : \mu \neq 0$ , kde  $\mu \in \mathbb{R}$ . Víme, že  $\varrho_0 = \frac{1}{2}$ , a tedy  $\varrho_1 = \frac{1}{2}$  (tzn.  $H_0$  věříme na 50%). Potom volíme

a) nejprve

$$\pi(\mu) = \frac{1}{2}\delta_0 + \frac{1}{2}\pi_1(\mu), \text{ kde } \pi_1(\mu) = 1 \text{ na } \mu \neq 0 \quad (\text{nevlastní apriorní hustota}).$$

Potom po dosazení dostaneme

$$\pi(\mu = 0 | \underbrace{\mathbf{x}}_{=x}) = \frac{1}{1 + \sqrt{2\pi}e^{x^2/2}} \stackrel{\forall x \in \mathbb{R}}{\leq} \frac{1}{1 + \sqrt{2\pi}} = 0.285, \quad \text{tzn. vždy zamítáme } H_0!$$

b) Nyní budeme předpokládat, že  $\pi_1(\mu) = \mathcal{N}(\mu = 0, \tau^2)$  (vlastní),  $\varrho = \frac{1}{2}$ . Oproti minulému příkladu, kdy jsme o rozdělení  $\mu$  vůbec nic nevěděli najednou máme k dispozici alespoň normální rozdělení. Z toho už se něco dá vyvozovat. Platí tedy, že

$$\pi(\mu = 0|\mathbf{x}) = [\dots]^{-1} \xrightarrow{\tau \rightarrow +\infty} 1.$$